Enterprise MLOps Cloud Open Source

kt cloud

CLOUD

사용자 가이드 (GUI)

Disclaimer
This document may contain undisclosed information.
Permission from Lablup Inc. is mandatory to access
the information in this slide document.

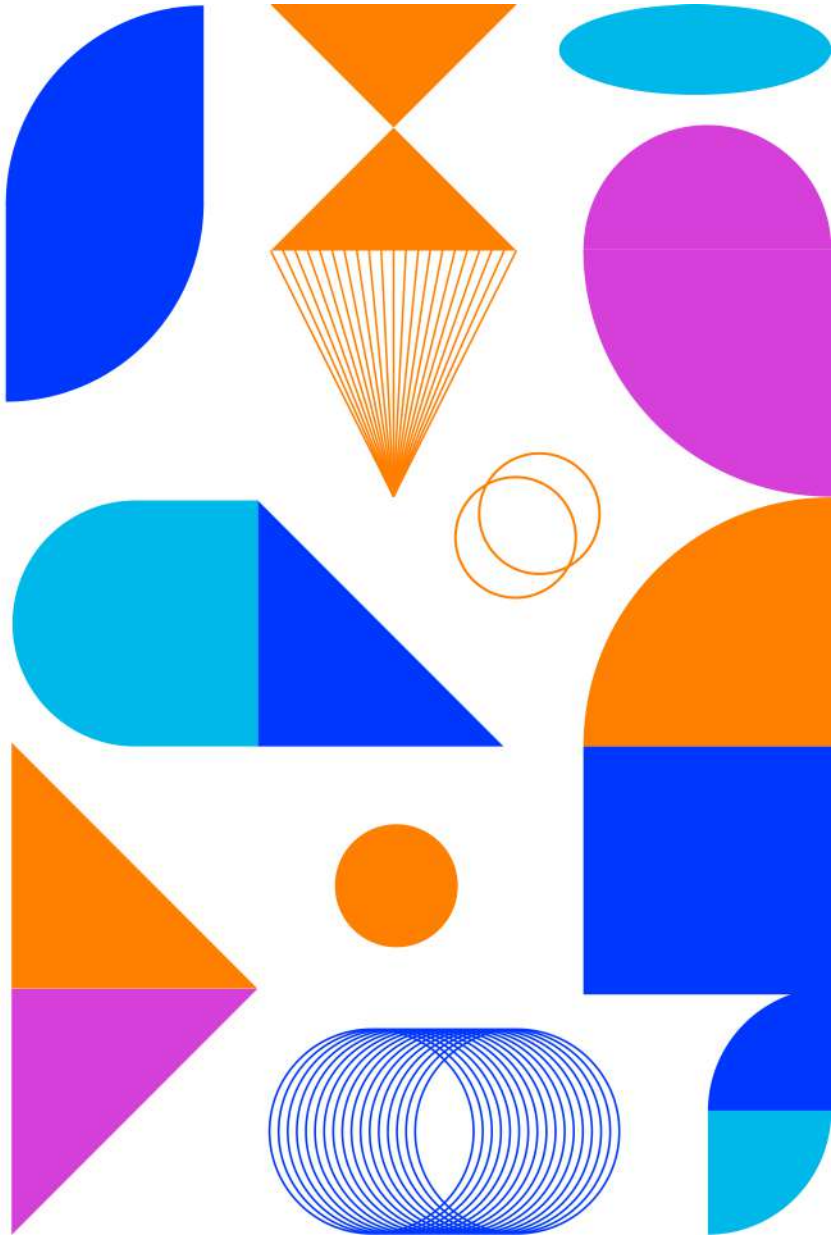

Contents: User Training (GUI)

- 시작하기
  - 사용자 설정
- 자원 관리
  - 프로젝트
  - 자원 그룹
  - 자원 정책
- 저장공간 다루기
  - 폴더 생성
  - 자동 마운트 폴더
  - 폴더 삭제
- 세션
  - 세션 시작
  - 세션 활용
  - 세션 종료
- 노트북 실행 & 저장소 가져오기
- 컨테이너 커밋

kt cloud CLOUD

lablup

시작하기

보안을 위해 최대 **12시간**까지 로그인 세션이 유지됩니다. 연장해야 할 경우 새로고침 버튼을 눌러 **로그인 세션을 연장**해 주시기 바랍니다.

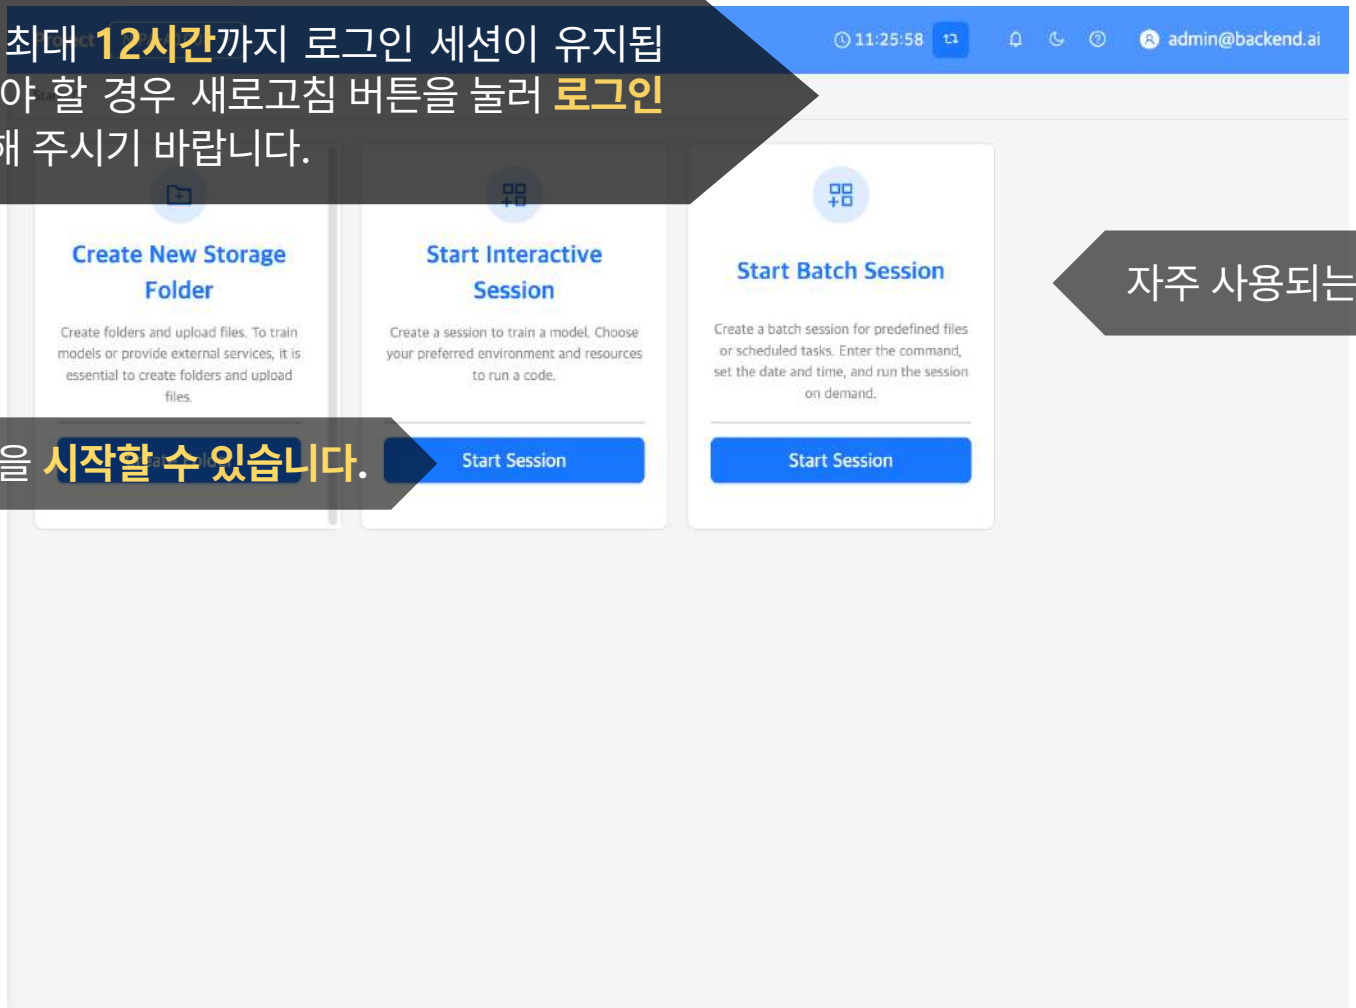

자주 사용되는 기능의 **단축 경로** 제공

여기서 세션을 **시작할 수 있습니다.**

시작하기

현재 프로젝트입니다.
(a.k.a. 유저 그룹)

공유 폴더로의 **초대**

사용중인 / 사용 가능한 **자원**들

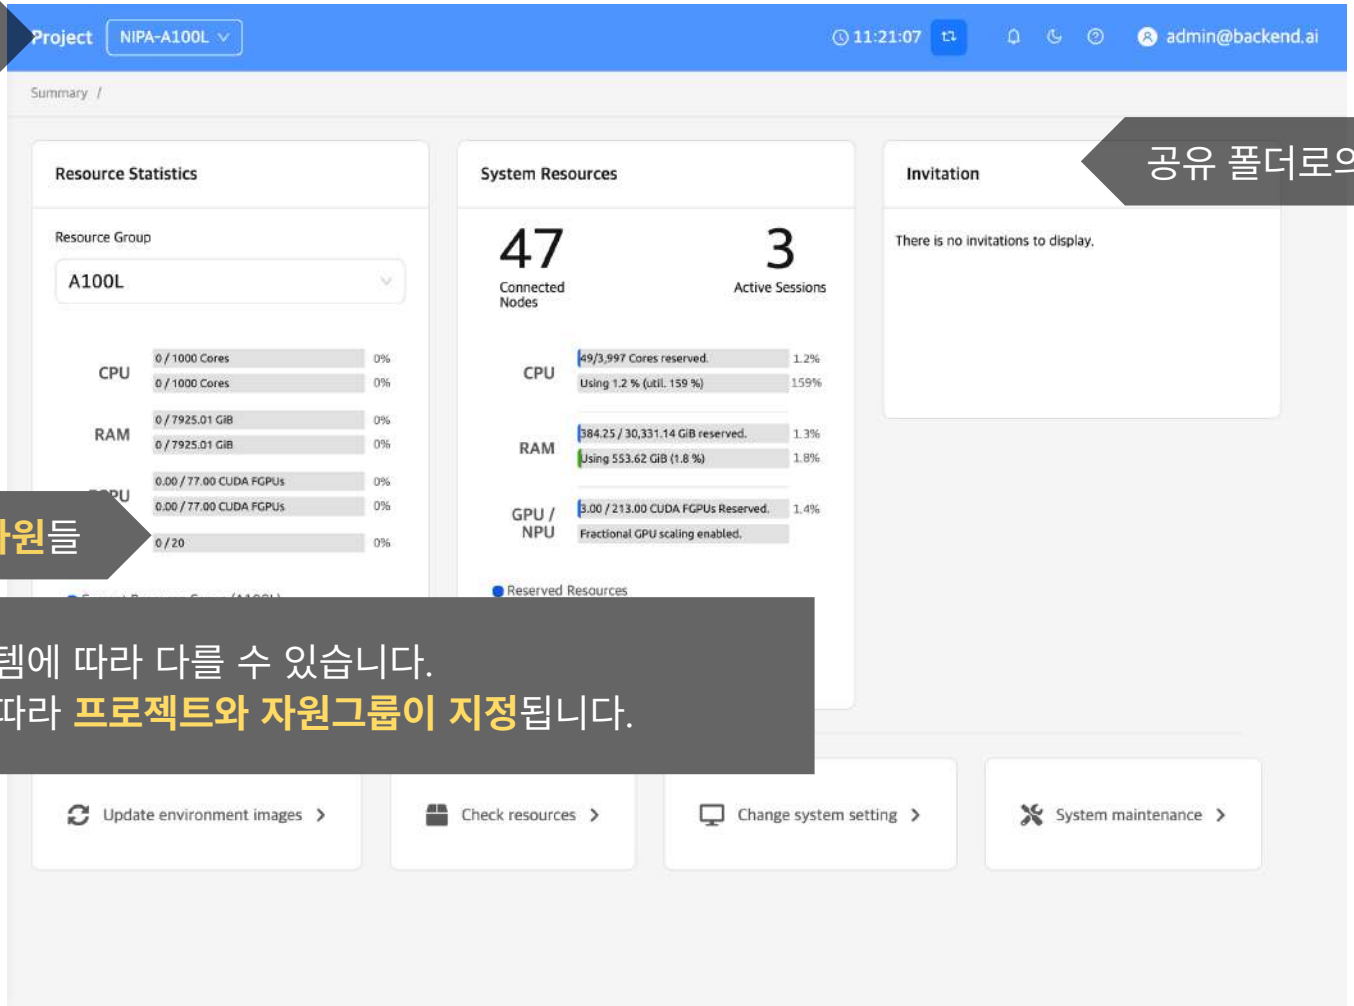

프로젝트 혹은 전체 시스템에 따라 다를 수 있습니다.
사용자는 선택한 상품에 따라 **프로젝트와 자원그룹이 지정**됩니다.

kt cloud CLOUD

lablup

시작하기 : 사용자 설정

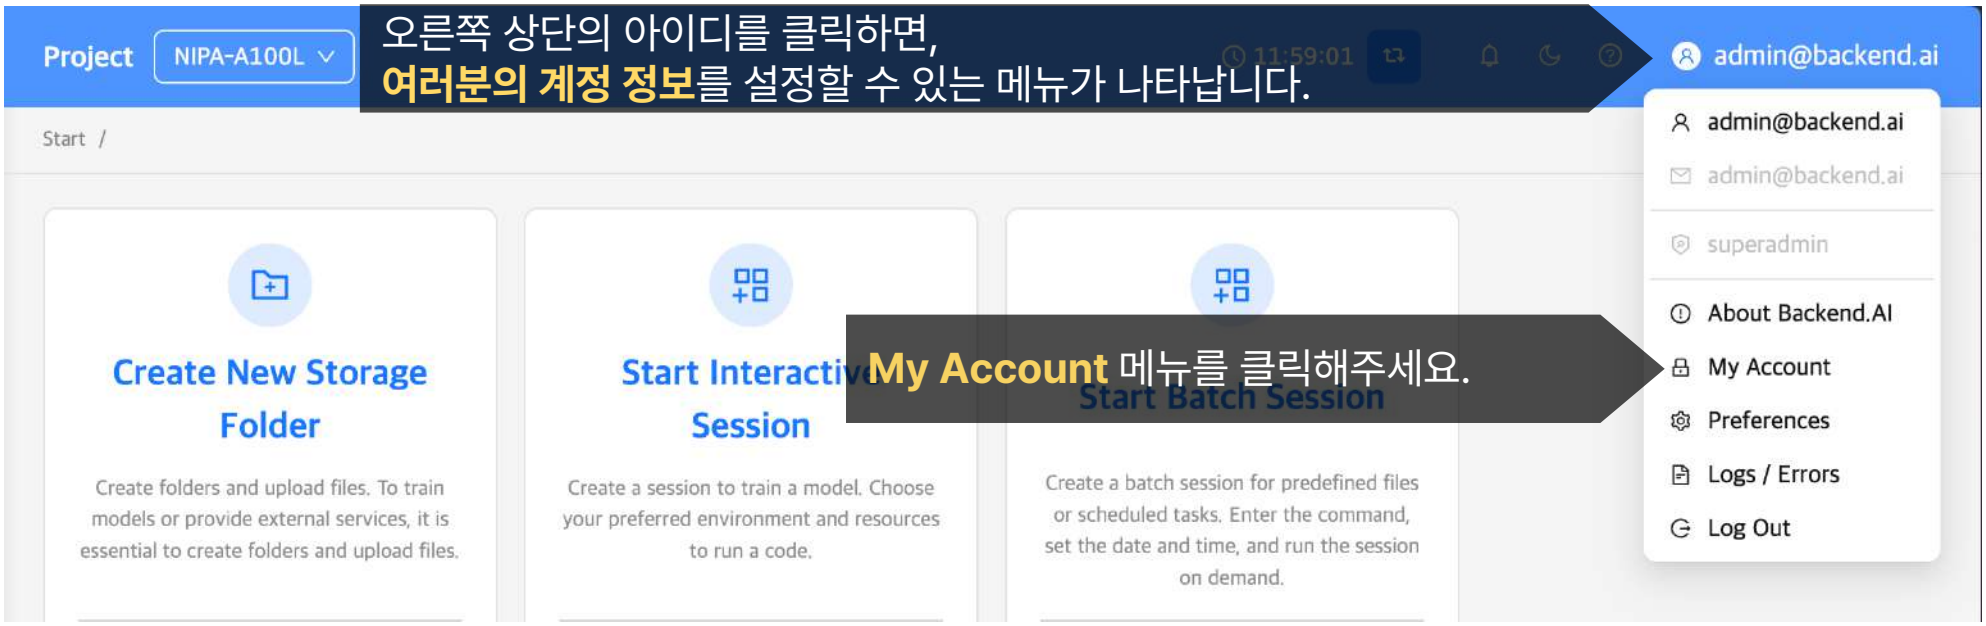
Project
NIPA-A100L
오른쪽 상단의 아이디를 클릭하면,
여러분의 계정 정보를 설정할 수 있는 메뉴가 나타납니다.
admin@backend.ai
Start /
admin@backend.ai
admin@backend.ai
superadmin
About Backend.AI
My Account
Preferences
Logs / Errors
Log Out
My Account 메뉴를 클릭해주세요.
Create New Storage Folder
Create folders and upload files. To train models or provide external services, it is essential to create folders and upload files.
Start Interactive Session
Create a session to train a model. Choose your preferred environment and resources to run a code.
Start Batch Session
Create a batch session for predefined files or scheduled tasks. Enter the command, set the date and time, and run the session on demand.

시작하기 : 사용자 설정

Project
NIPA-A100L
오른쪽 상단의 아이디를 클릭하면,
언어 설정과 같은 정보를 설정할 수 있는 메뉴가 나타납니다.
admin@backend.ai
admin@backend.ai
admin@backend.ai
superadmin
About Backend.AI
My Account
Preferences
Logs / Errors
Log Out
Start /
Create New Storage Folder
Create folders and upload files. To train models or provide external services, it is essential to create folders and upload files.
Start Interactive Session
Create a session to train a model. Choose your preferred environment and resources to run a code.
Start Batch Session
Create a batch session for predefined files or scheduled tasks. Enter the command, set the date and time, and run the session on demand.
Preferences 메뉴를 클릭해주세요.

시작하기 : 사용자 설정

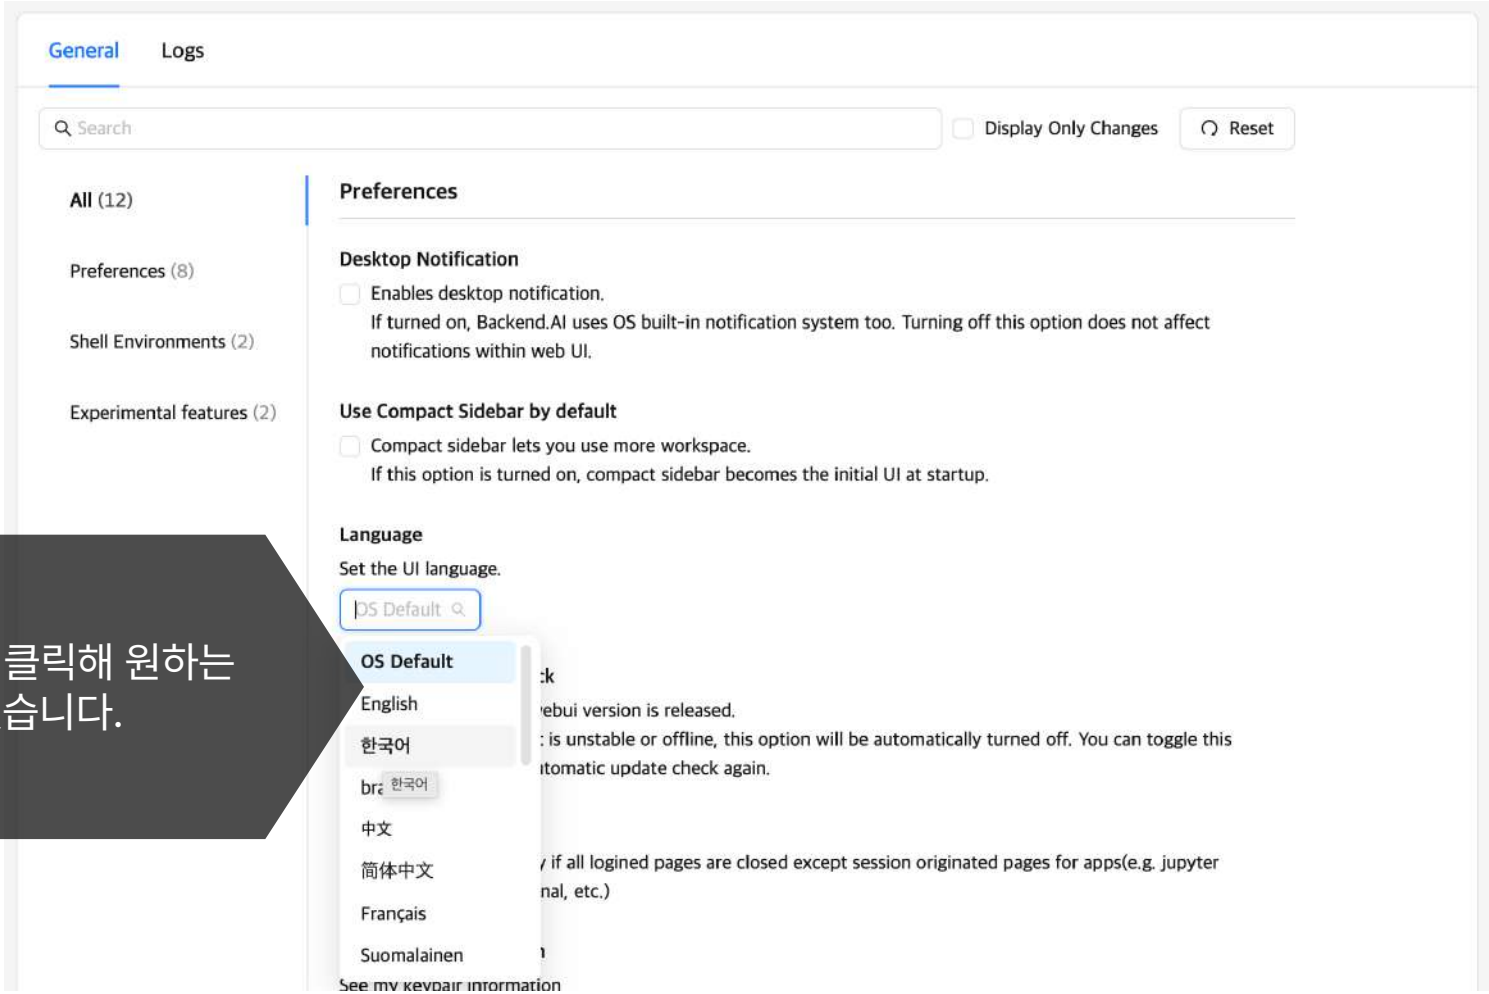

Language 메뉴를 클릭해 원하는 언어로 변경할 수 있습니다.

kt cloud CLOUD

lablup

시작하기 : 사용자 설정

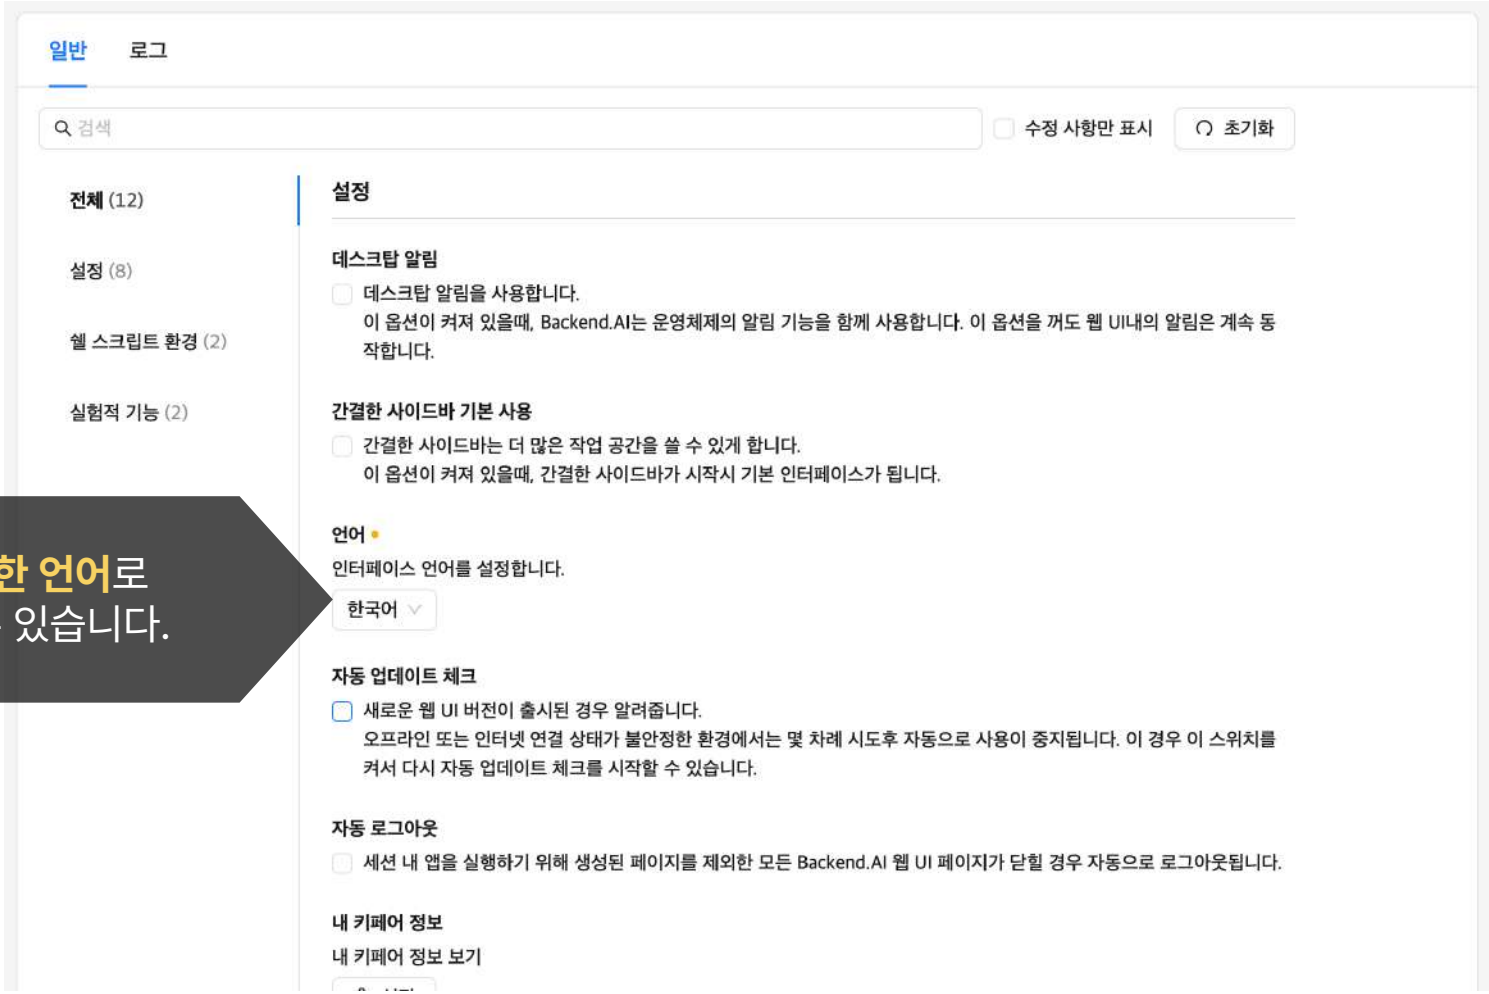

선택하면 즉시 **선택한 언어**로
바뀐 것을 확인할 수 있습니다.

kt cloud CLOUD

lablup

자원 관리 : 프로젝트

NOTE
실제 프로젝트 이름 및 접근가능한 프로젝트 수, 그에 따른 자원량은 정책에 따라 변경될 수 있습니다.

- 프로젝트: 미리 **할당된 자원을 공유**하는 최소한의 단위
  - '사용자 그룹', '팀' 또는 '프로젝트 그룹' 등으로 사용됩니다.
  - 사용자는 하나의 프로젝트 하위, 하나의 자원 그룹에 속할 수 있습니다
    - ✓ NIPA-A100L 또는 NIPA-A100Q 또는 NIPA-H100E 또는 NIPA-H100Q...

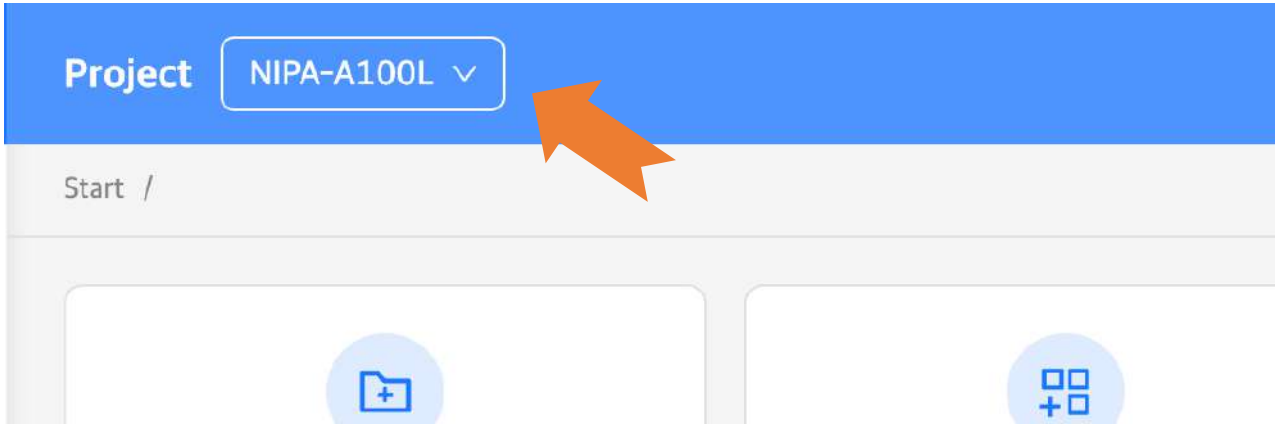

자원 관리 : 자원 그룹

- 자원 그룹: **하드웨어 리소스를 관리**하는 단위 그룹
  - 프로젝트별로 자원 그룹이 할당됩니다.
  - 사용자는 지정된 자원 그룹 내의 자원만을 이용해서 연산 세션을 생성할 수 있습니다.
  - 사용자는 할당된 자원 그룹 내 자원을 자유롭게 사용할 수 있습니다.

예시) NIPA-H100E **프로젝트에 H100E** 자원 그룹을 할당하고, **NIPA-A100Q 프로젝트에 A100Q** 자원 그룹을 할당합니다.

A 프로젝트에 소속된 사용자는 H100 GPU를 사용하게 되고, **B 프로젝트에 소속된 사용자는 A100 GPU**를 사용하게 됩니다.

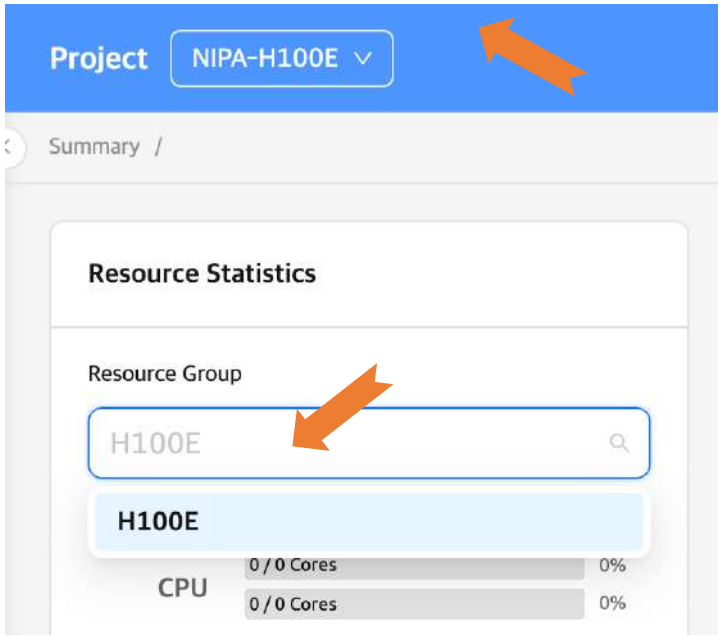

kt cloud CLOUD

lablup

자원 관리 : 자원 정책

- 자원 정책: 사용자(키페어)별로 최대 사용 가능한 **자원량을 제한**하는 방법
  - 정책상 한 사람당 최대 **3개의 세션과 5개의 폴더**를 생성할 수 있습니다.
  - NIPA 사업에서 제공되는 상품 스펙 기준으로 자원 정책이 할당됩니다.

프로젝트	자원 그룹	자원 정책
NIPA-A100L	A100L	CPU: 24 Core MEM: 192 GiB FGPU: 2 Unit Cluster Size: 3
NIPA-A100Q	A100Q	CPU: 24 Core MEM: 192 GiB FGPU: 8 Unit Cluster Size: 3
NIPA-H100E	H100E	CPU: 48 Core MEM: 48 GiB FGPU: 16 Unit Cluster Size: 3

자원할당 정책 예시*

저장공간 다루기

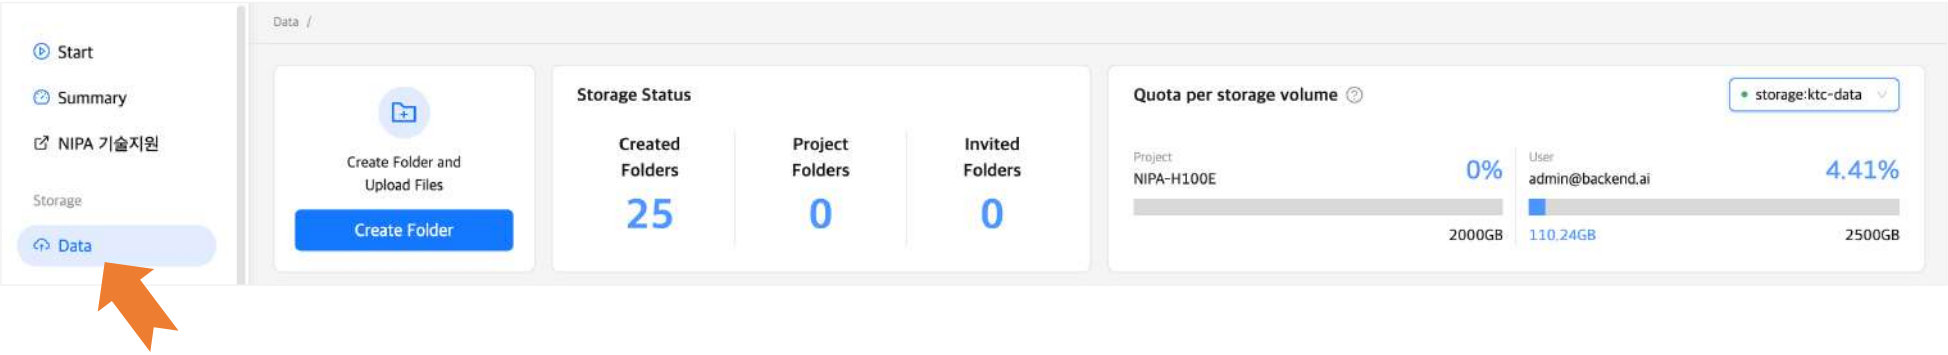

데이터 & 폴더 페이지에서는,
사용자의 파일을 보존할 수 있는 다수의 **개인, 프로젝트 폴더를 관리**합니다.
연산 세션의 기본 폴더는 세션이 삭제되면 같이 삭제되므로, 보존해야 하는 파일이 있을 경우 세션 생성 시 데이터 폴더를 마운트 하여 저장하는 것이 좋습니다.

저장공간 다루기

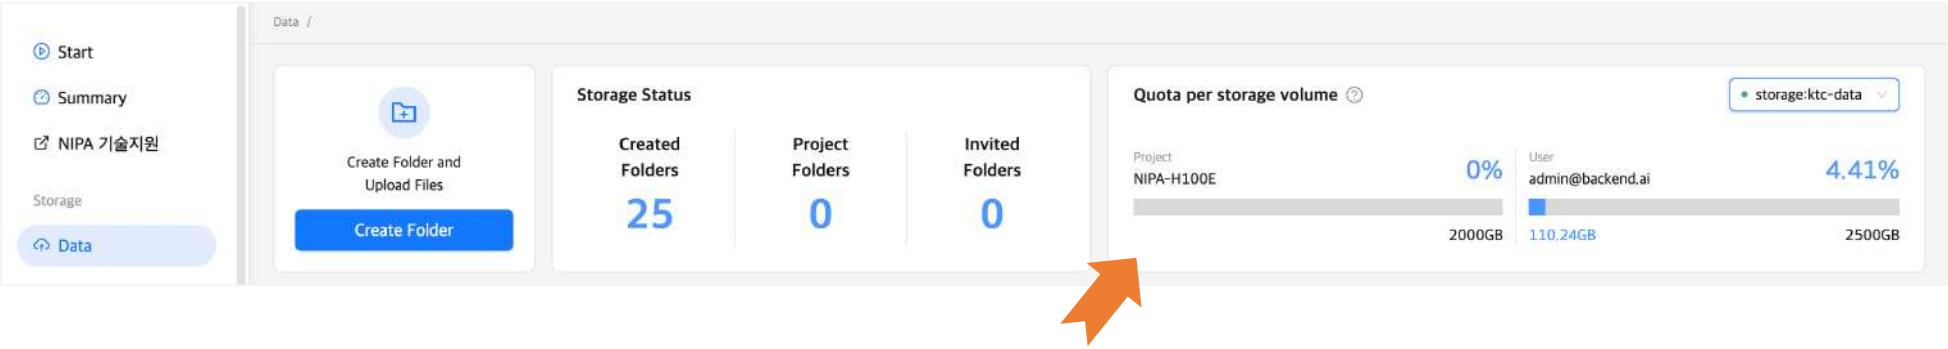

또한 관리자 설정에 따라 **저장공간이 제한**될 수 있습니다. 이 때 제한되는 용량은 저장공간 별로 상이할 수 있으며, **용량을 초과하는 파일 또는 폴더는 업로드가 불가**합니다. 선택된 프로젝트에서 관리되는 프로젝트 폴더의 용량과 사용자가 관리하는 사용자 폴더의 용량을 각각 **저장소 별 쿼타 정보**에서 확인할 수 있습니다.

저장공간 다루기 : 새 폴더 추가

사용자가 접근가능한 프로젝트, 자원그룹에 따라 스토리지 호스트는 상이할 수 있습니다.

e.g.)

자원 그룹	스토리지 호스트
NIPA-A100L	ktc-data
NIPA-A100Q	ktc-data
NIPA-H100Q	ktc-data
NIPA-H100E	AITRAIN_DATA1 또는 AITRAIN_DATA2

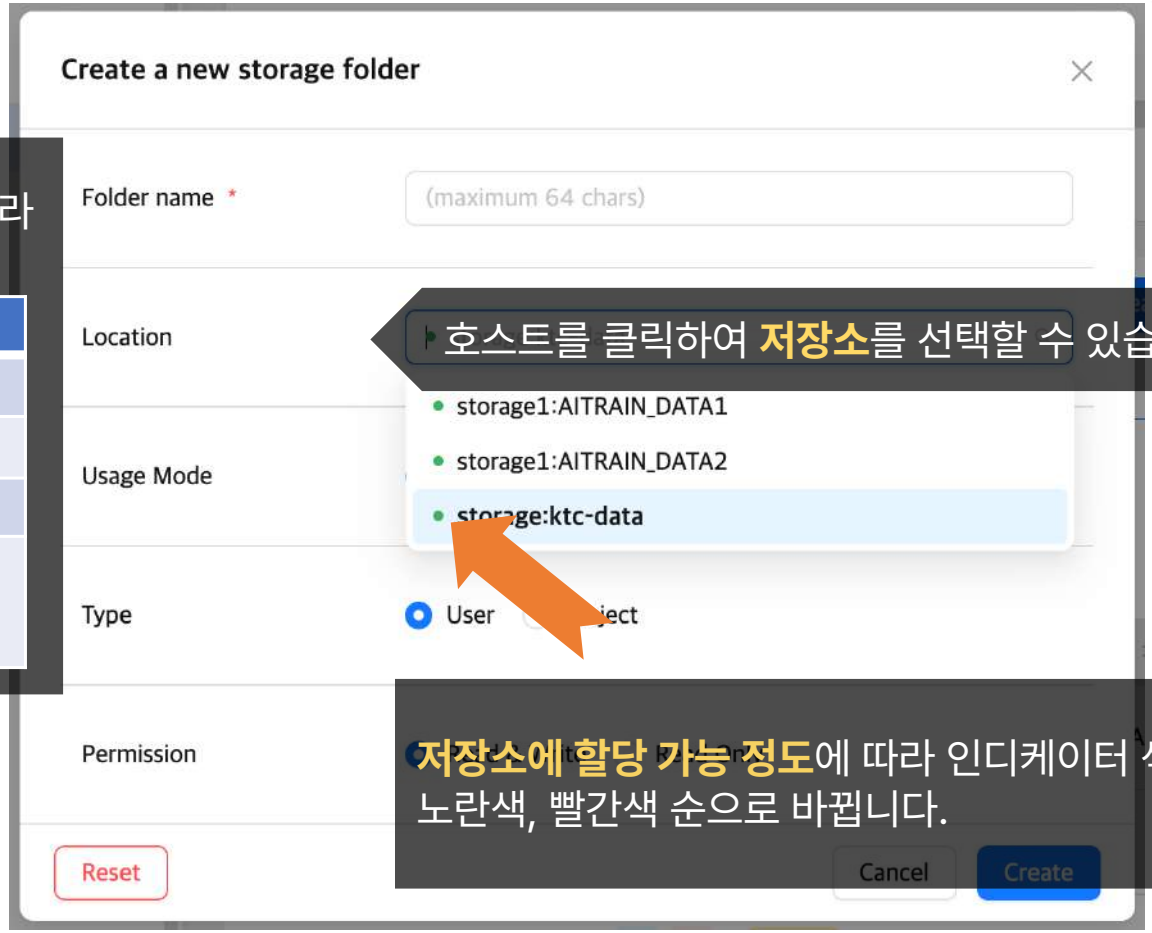

호스트를 클릭하여 **저장소**를 선택할 수 있습니다.

저장소에 할당 가능 정도에 따라 인디케이터 색이 초록색, 노란색, 빨간색 순으로 바뀝니다.

저장공간 다루기 : 파일 업로드

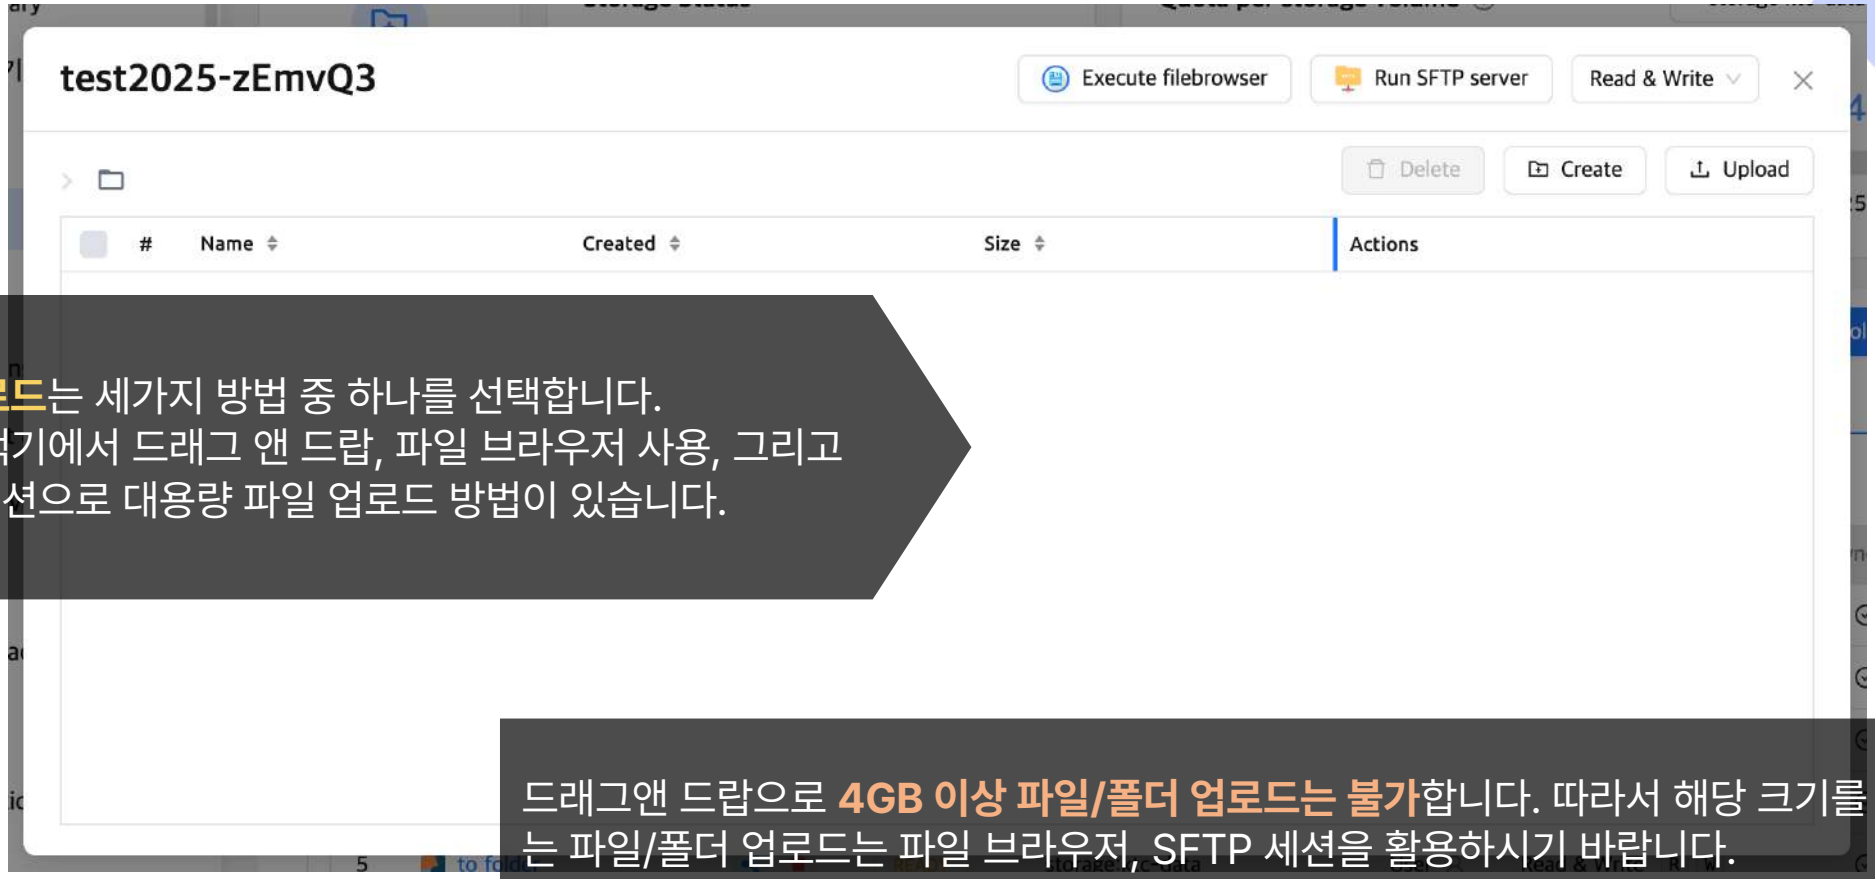

파일 업로드는 세가지 방법 중 하나를 선택합니다.
폴더 탐색기에서 드래그 앤 드랍, 파일 브라우저 사용, 그리고 SFTP 세션으로 대용량 파일 업로드 방법이 있습니다.

드래그앤 드랍으로 **4GB 이상 파일/폴더 업로드는 불가**합니다. 따라서 해당 크기를 초과하는 파일/폴더 업로드는 파일 브라우저, SFTP 세션을 활용하시기 바랍니다.

저장공간 다루기 : 파일 업로드

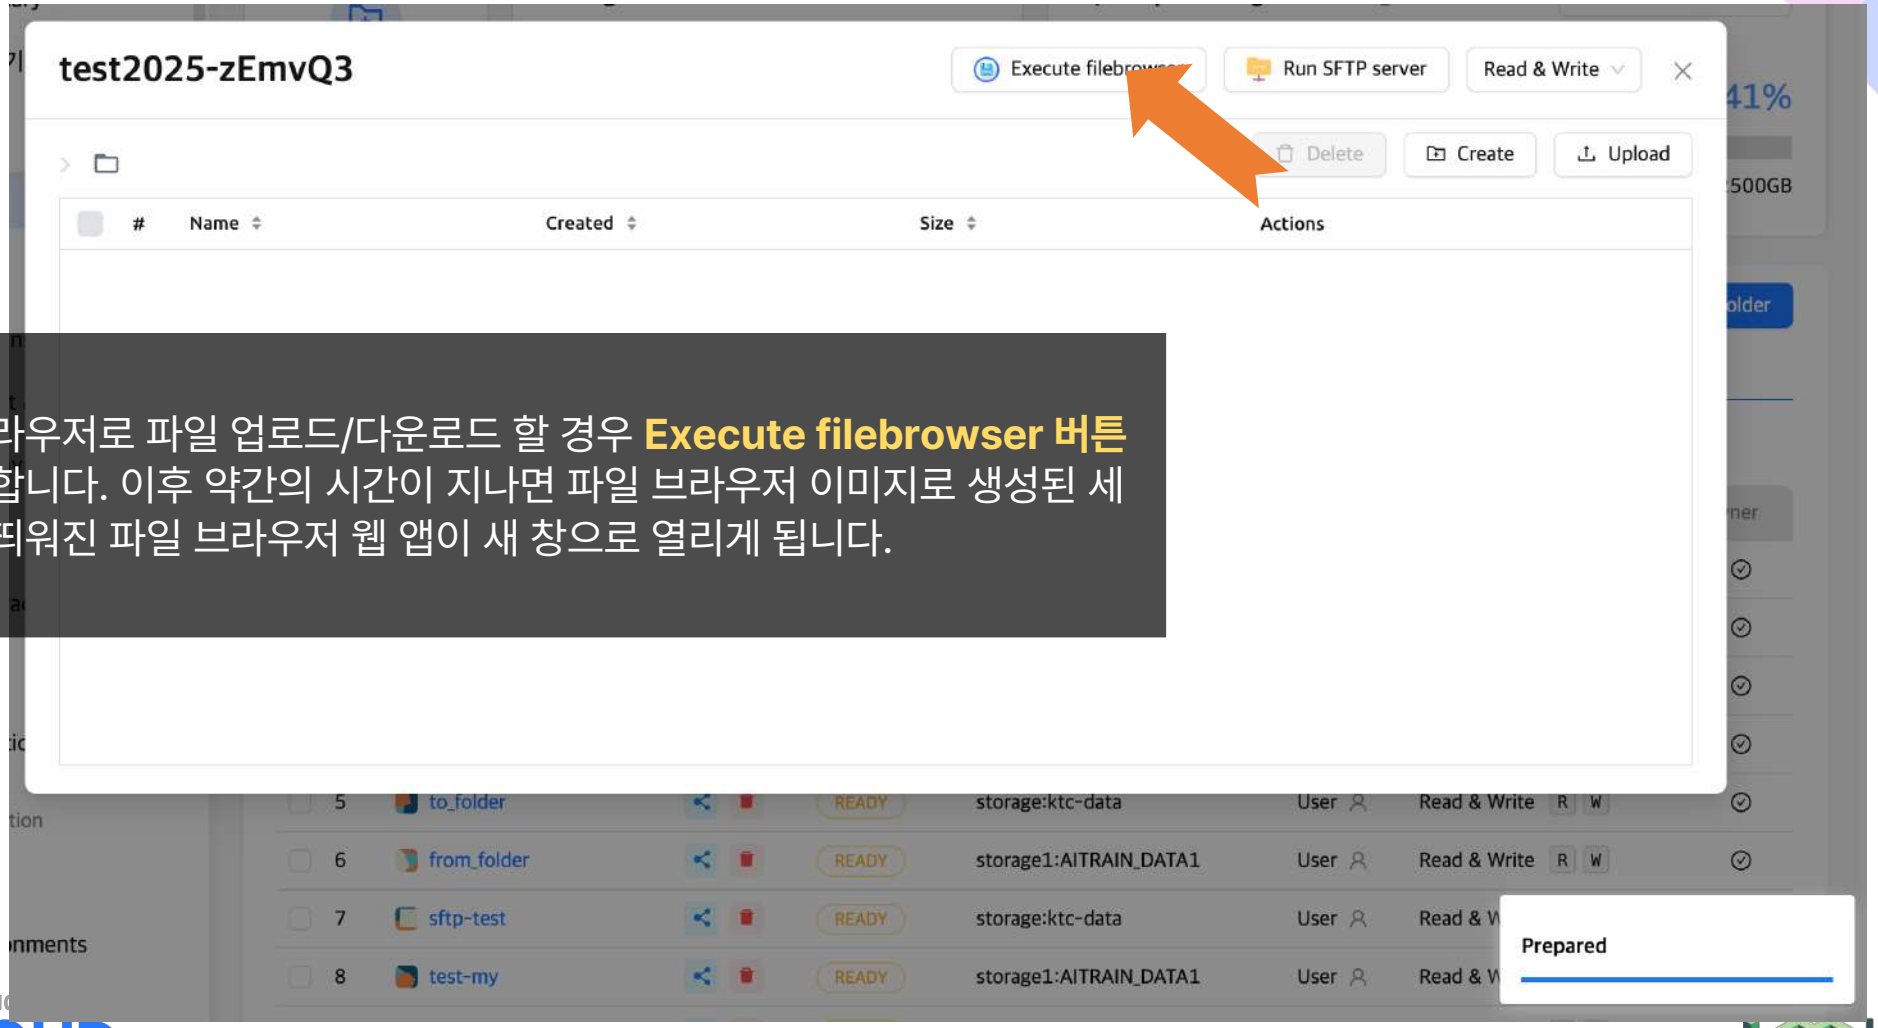

파일 브라우저로 파일 업로드/다운로드 할 경우 **Execute filebrowser 버튼**을 클릭합니다. 이후 약간의 시간이 지나면 파일 브라우저 이미지로 생성된 세션에서 띄워진 파일 브라우저 웹 앱이 새 창으로 열리게 됩니다.

저장공간 다루기 : 파일 업로드

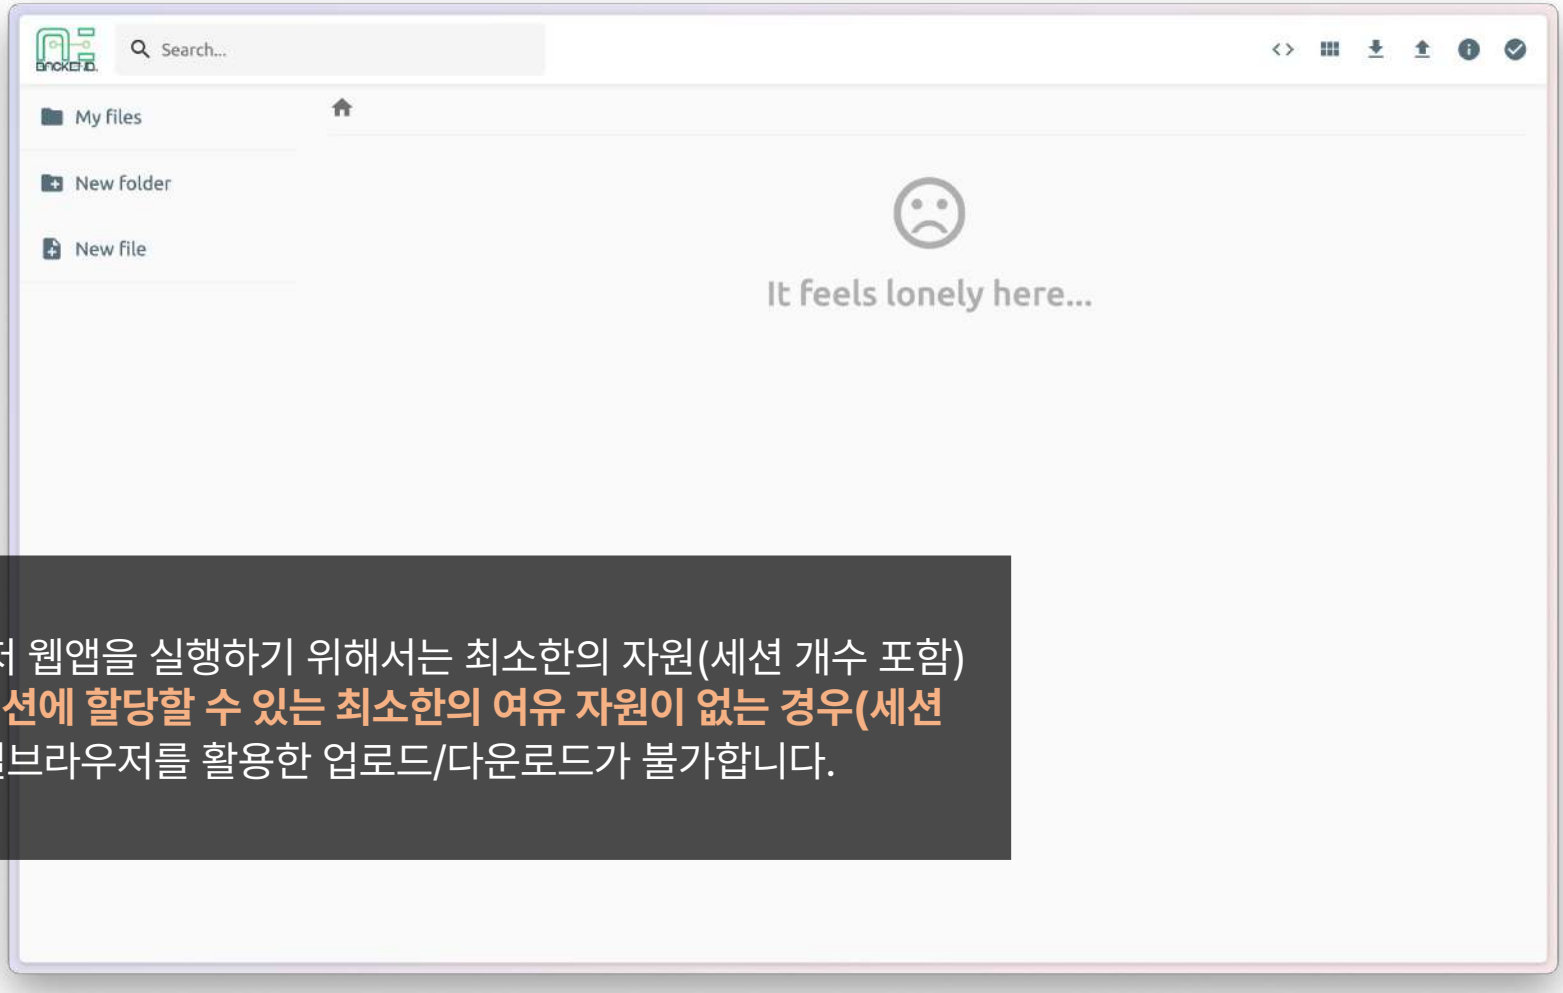

해당 파일브라우저 웹앱을 실행하기 위해서는 최소한의 자원(세션 개수 포함)이 필요합니다. **세션에 할당할 수 있는 최소한의 여유 자원이 없는 경우(세션 개수 포함)**는 파일브라우저를 활용한 업로드/다운로드가 불가합니다.

kt cloud CLOUD

lablup

저장공간 다루기 : 파일 업로드

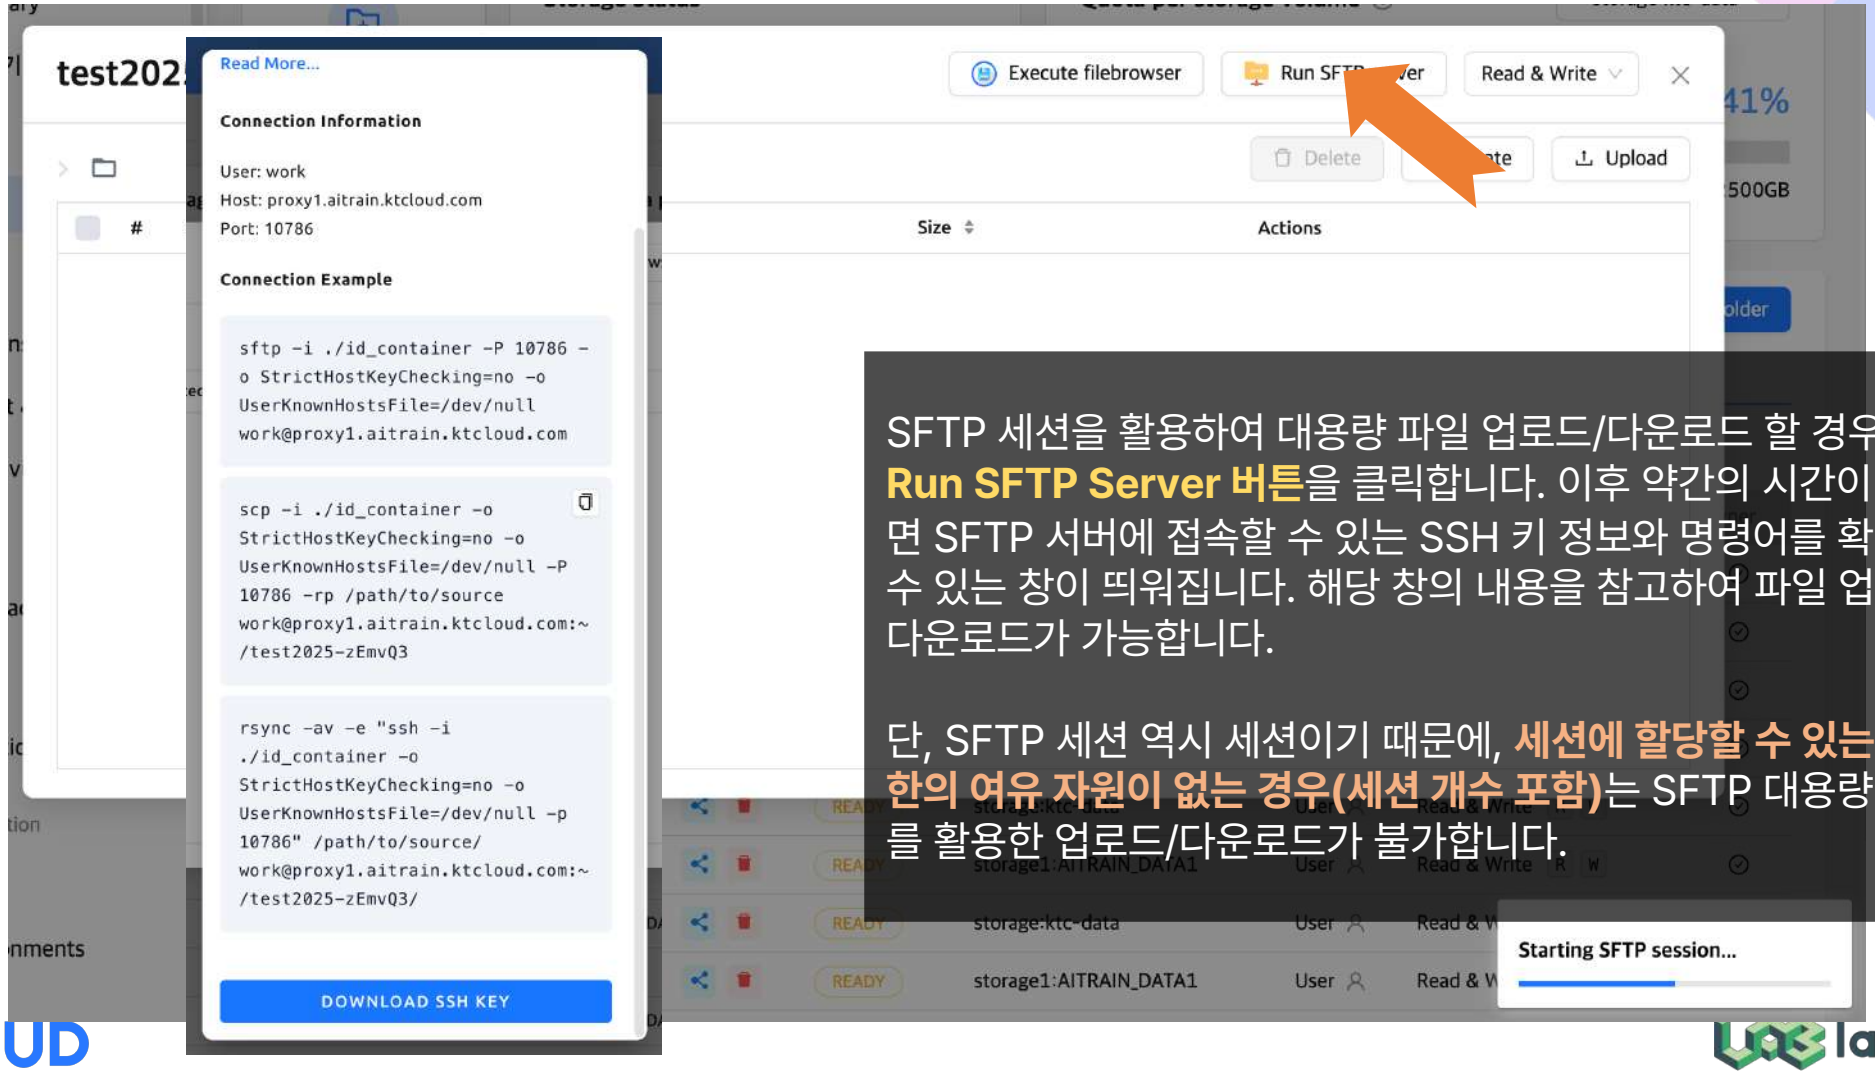

SFTP 세션을 활용하여 대용량 파일 업로드/다운로드 할 경우, **Run SFTP Server 버튼**을 클릭합니다. 이후 약간의 시간이 지나면 SFTP 서버에 접속할 수 있는 SSH 키 정보와 명령어를 확인할 수 있는 창이 띄워집니다. 해당 창의 내용을 참고하여 파일 업로드/다운로드가 가능합니다.

단, SFTP 세션 역시 세션이기 때문에, **세션에 할당할 수 있는 최소한의 여유 자원이 없는 경우(세션 개수 포함)**는 SFTP 대용량 서버를 활용한 업로드/다운로드가 불가합니다.

저장공간 다루기 : 자동 마운트 폴더

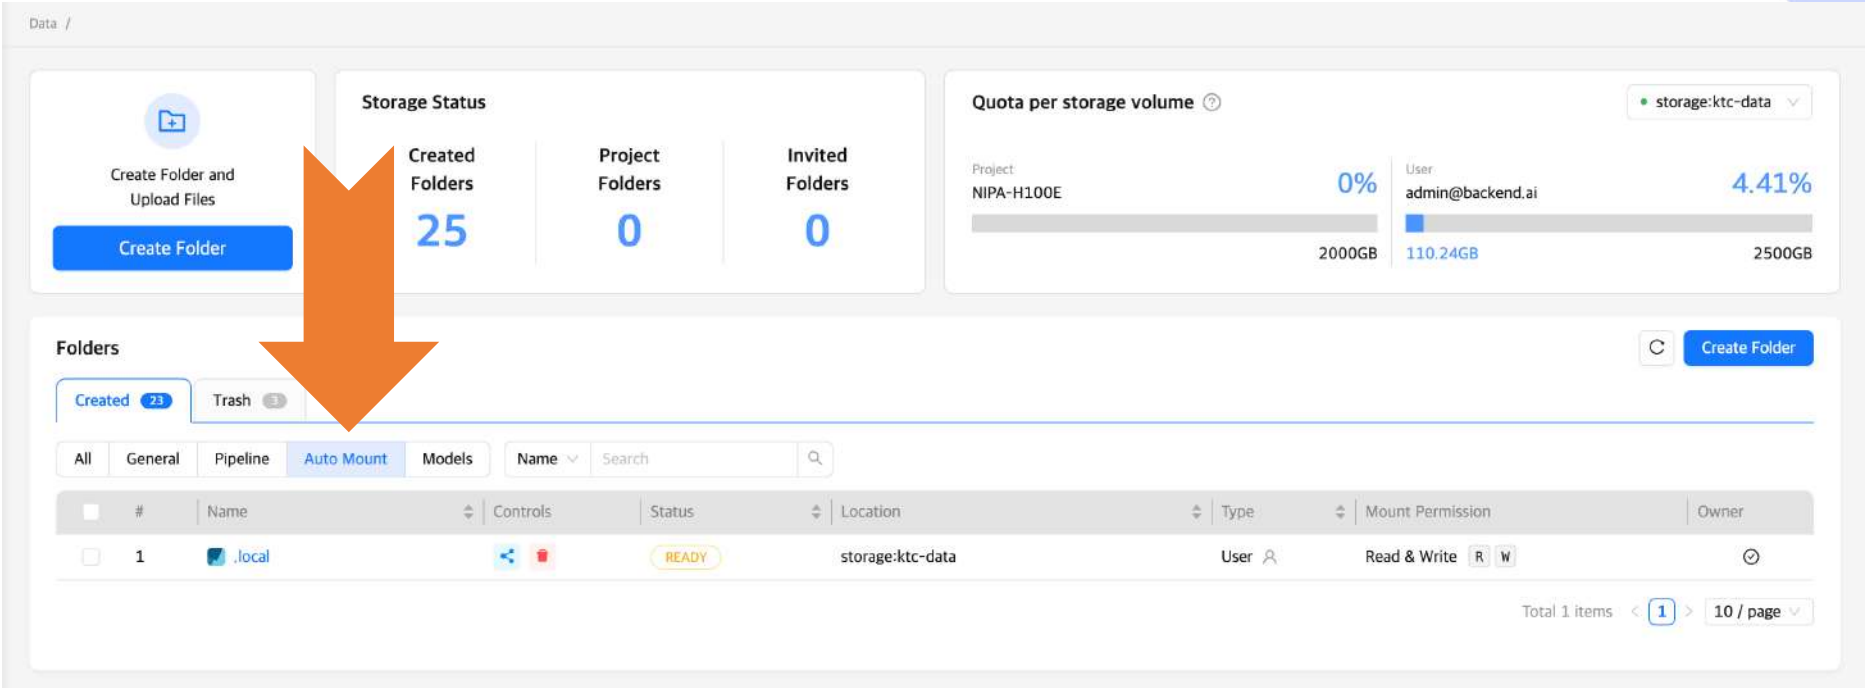

자동 마운트 폴더들은 세션 시작 시에 **자동으로 마운트되는 폴더들입니다.**
자동 마운트 폴더 탭에서는 자동 마운트된 폴더들의 목록을 볼 수 있습니다.

kt cloud CLOUD

lablup

저장공간 다루기 : 자동 마운트 폴더

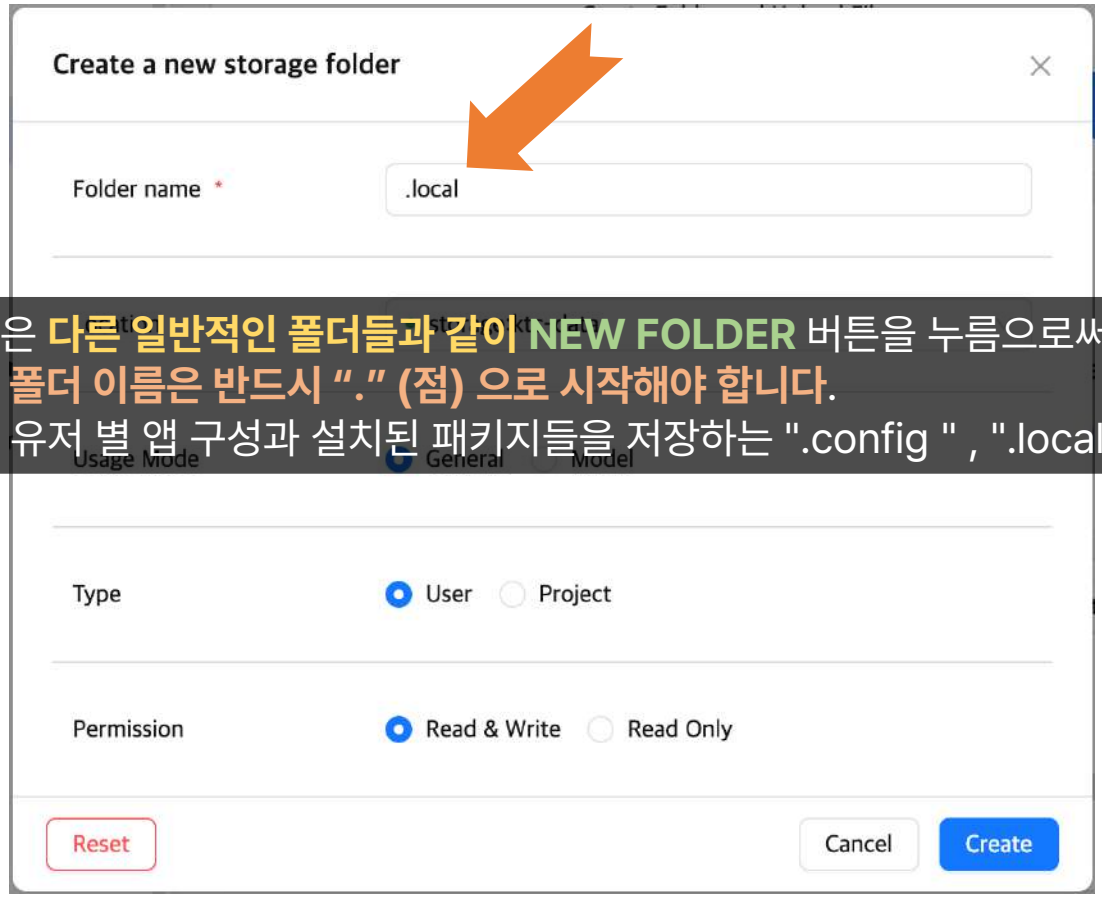

자동 마운트 폴더들은 **다른 일반적인 폴더들과 같이 NEW FOLDER** 버튼을 누름으로써 생성됩니다.
그러나 **자동 마운트 폴더 이름은 반드시 "." (점) 으로 시작해야 합니다.**
대표적인 예로는 각 유저 별 앱 구성과 설치된 패키지들을 저장하는 ".config " , ".local " 가 있습니다.

저장공간 다루기 : 폴더 삭제 - 휴지통으로 이동

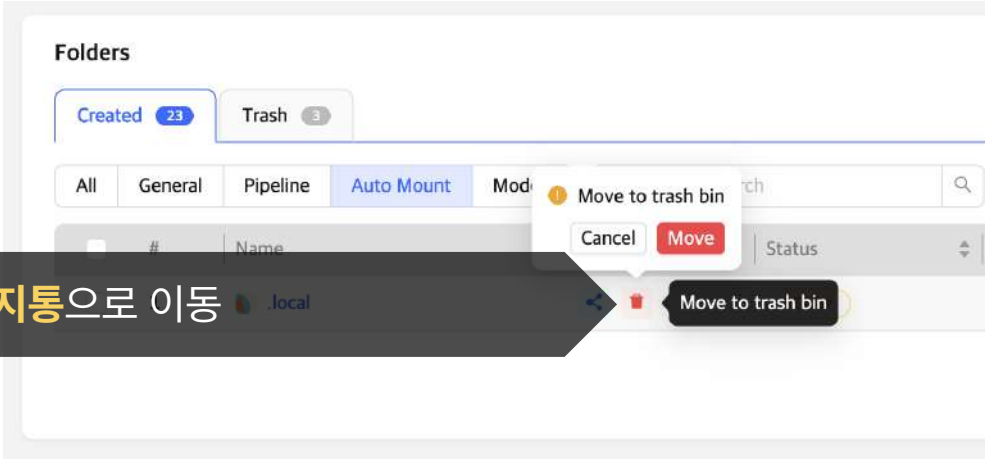

휴지통으로 이동

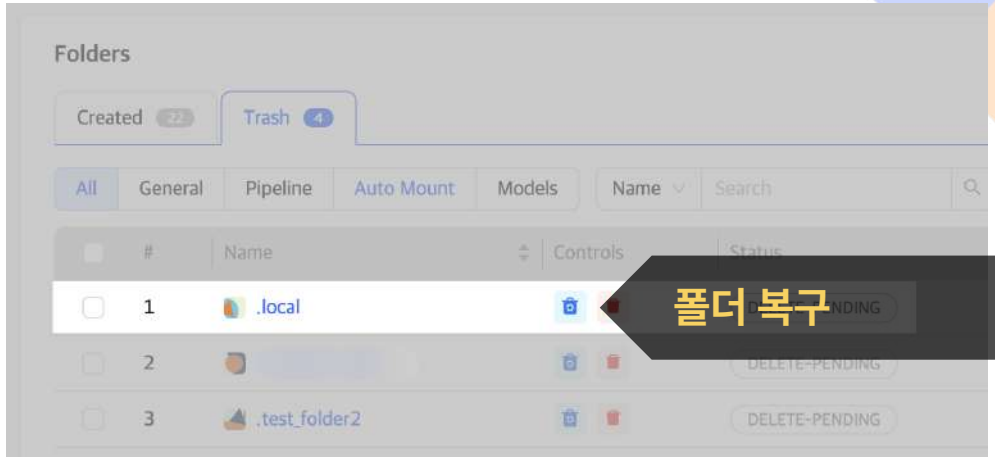

폴더 복구

폴더 삭제는 **휴지통으로 이동** 단계와 **영구 삭제** 단계로 구분됩니다.
Controls열의 휴지통 버튼을 클릭해 폴더를 휴지통으로 이동할 수 있습니다.
휴지통으로 이동된 폴더는 복구 버튼을 클릭해 다시 사용할 수 있습니다.

휴지통으로 이동된 폴더는 폴더 리스트의 **Trash 탭**에서 확인이 가능합니다.

저장공간 다루기 : 폴더 삭제 - 휴지통으로 이동

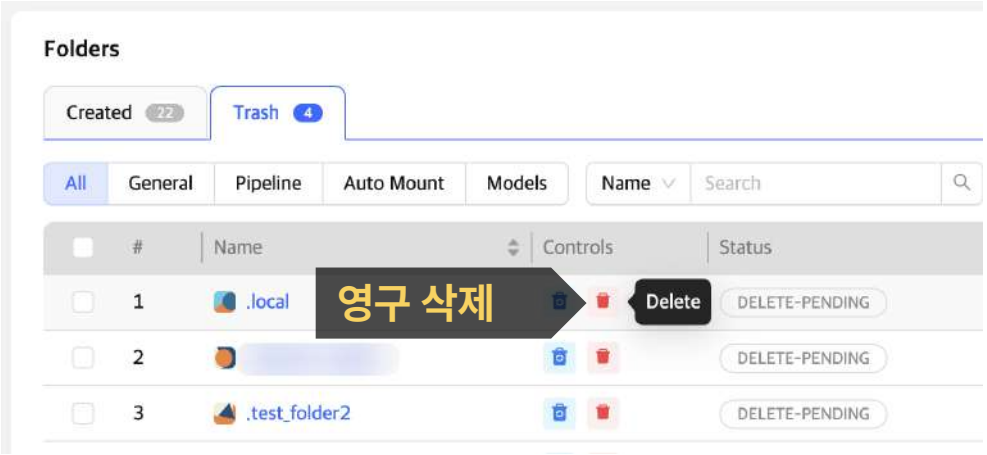

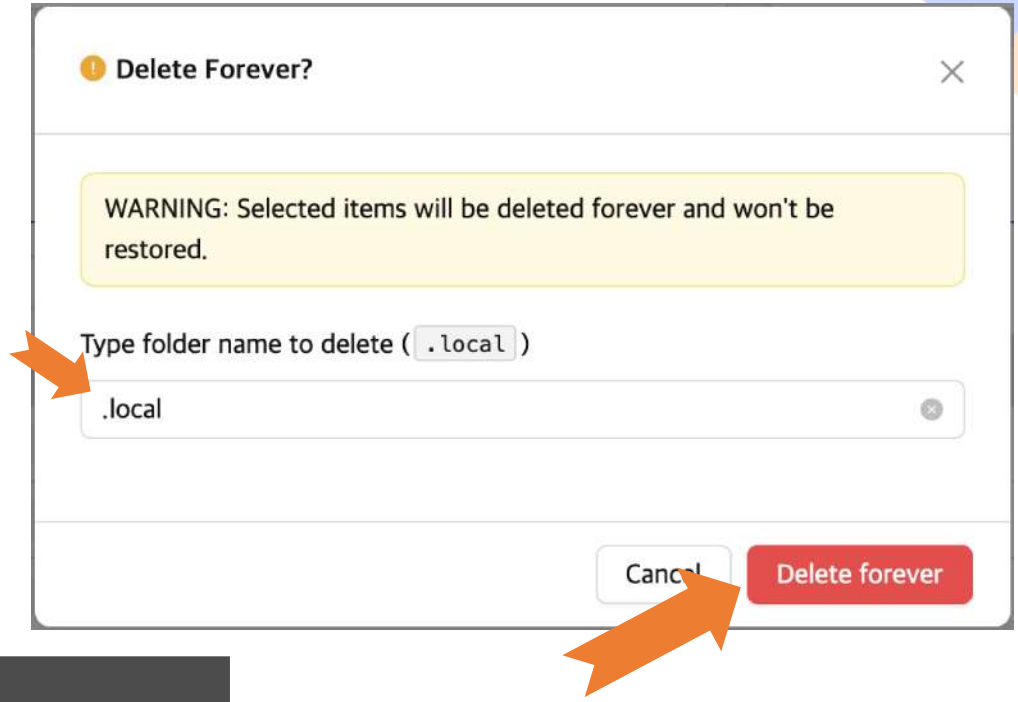

휴지통으로 이동된 폴더는 **영구 삭제**가 가능합니다.
삭제 버튼을 클릭해 표시된 모달에서 **폴더 이름**을 입력한 후, **영구 삭제 버튼**을 눌러 삭제를 완료할 수 있습니다.

kt cloud CLOUD

lablup

세션에 대해 자주하는 질문

Q. 제공되는 환경이 일반 VM 이나 Baremetal 환경이 아닌 컨테이너 기반의 서비스라고 설명 들었는데 차이점이 뭔가요?

A. 저희가 제공하는 GPU 학습 환경은 도커 컨테이너(Docker container) 기반의 서비스 입니다.

도커 컨테이너는 애플리케이션과 그 종속성을 하나의 패키지로 묶어주는 기술입니다. 컨테이너는 호스트 운영 체제 위에서 실행되며, 별도의 운영 체제를 필요로 하지 않습니다. 학습 환경에서 도커 컨테이너를 사용할 경우 VM 환경보다 쉽고 빠르게 자원 확장, 축소가 가능하므로 효율적인 관리가 가능합니다. 특히 딥러닝 및 고성능 컴퓨팅 연산 자원관리에 최적화 되어 있습니다. 가령 장애 발생 시 중단된 시점부터 재시작하거나 동일 인스턴스를 시작하는 등, 다양한 장애 대응 옵션을 제공합니다. 따라서 성능 확보가 중요한 딥러닝 학습, 서비스 환경에서는 도커 컨테이너를 활용해 빠르게 할당/회수하는 시스템을 추천합니다.

세션에 대해 자주하는 질문

Q. 제공받은 서비스에 도커(Docker)가 설치된 것으로 확인되는데 도커 데몬(docker daemon) 이 돌아가지 않습니다. 제공 받은 환경에서 여러 개의 컨테이너를 띄워서 학습하려고 하는데 도움 부탁드립니다.

A. 저희가 제공하는 환경은 도커 컨테이너(Docker container) 기반의 환경입니다. 사용하고 계시는 환경은 이미 컨테이너 내부에서 작업하는 것으로 도커-인-도커(docker-in-docker) 는 로우 레벨(low level)의 기술적 문제를 많이 일으키고 성능/보안 상 권장되지 않으며 해당 작업으로 인한 기술적인 오류/결함은 지원하지 않습니다.

세션 : 세션 시작 - 단일 노드 세션

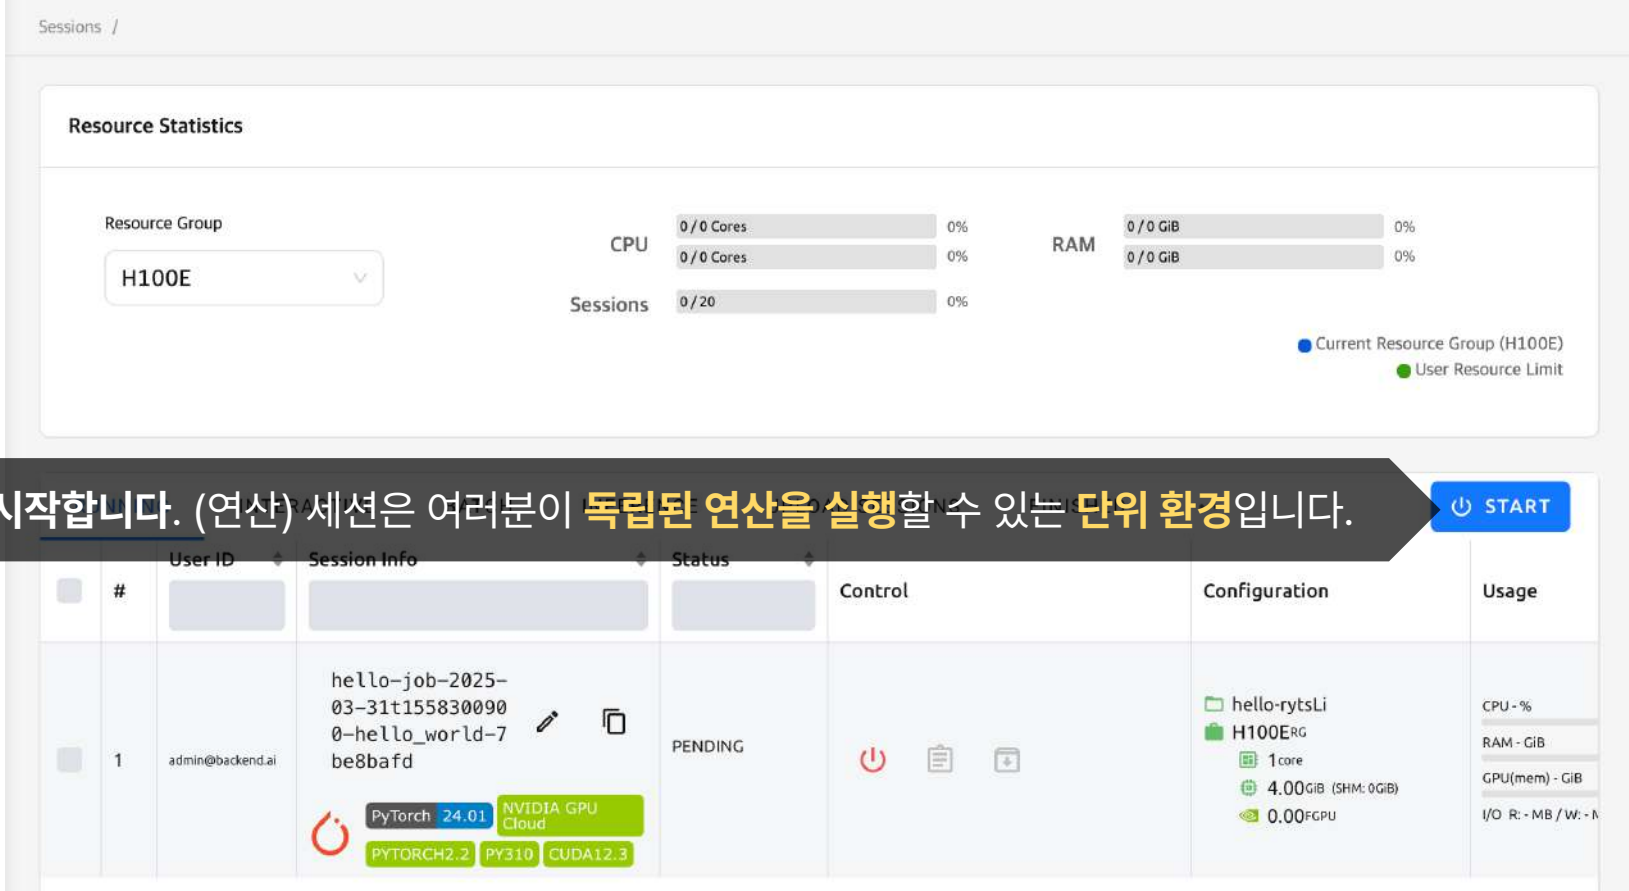

새로운 세션을 시작합니다. (연산) 세션은 여러분이 **독립된 연산을 실행**할 수 있는 **단위 환경**입니다.

세션 : 세션 시작 - 단일 노드 세션

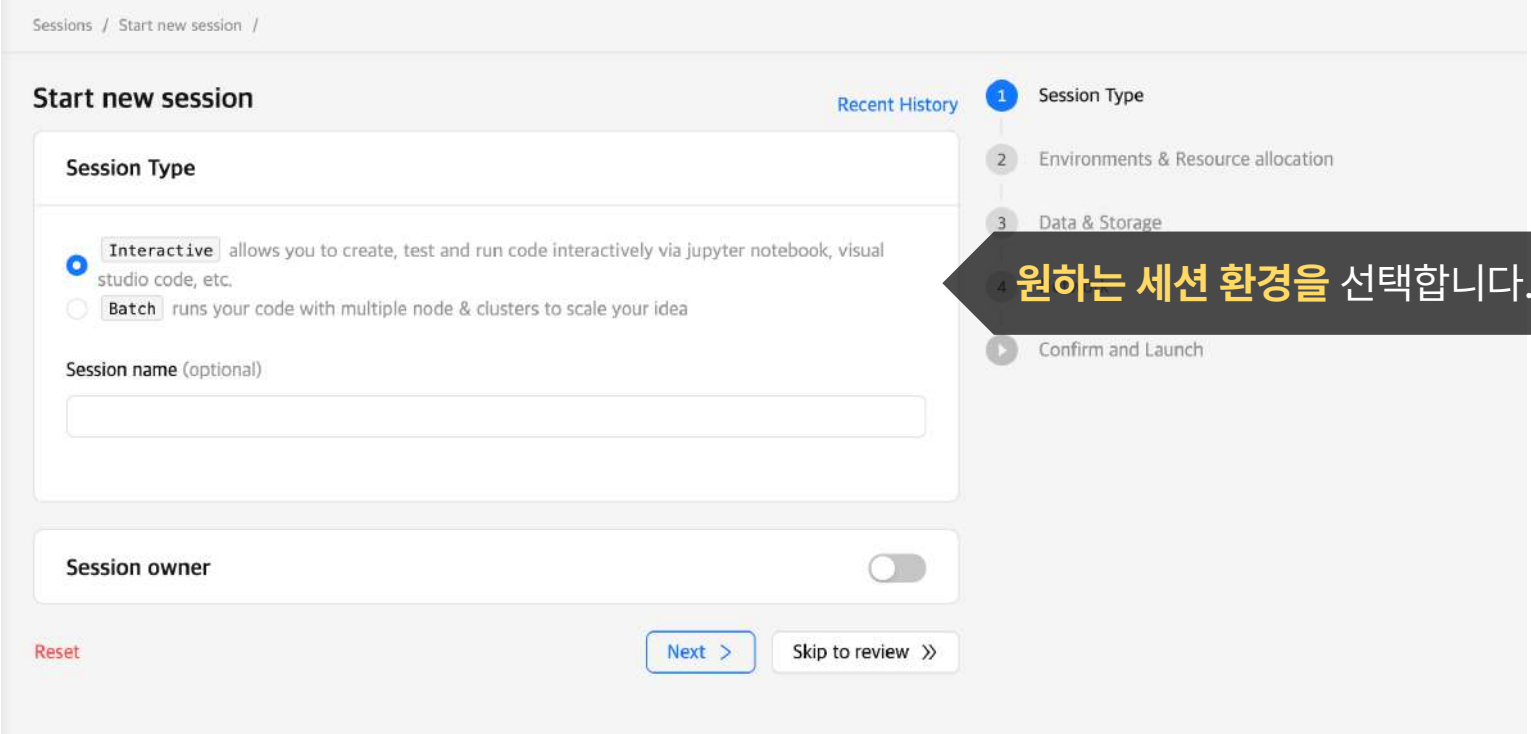

원하는 세션 환경을 선택합니다.

Interactive 세션: 별도의 실행 스크립트를 지정하지 않고 일단 세션을 생성한 후 상호 작용하는 방식
Batch 세션: 자원이 할당되는 즉시 해당 스크립트를 실행하고, 스크립트가 종료됨과 동시에 연산 세션이 자동 삭제되는 방식

세션 : 세션 시작 - 단일 노드 세션

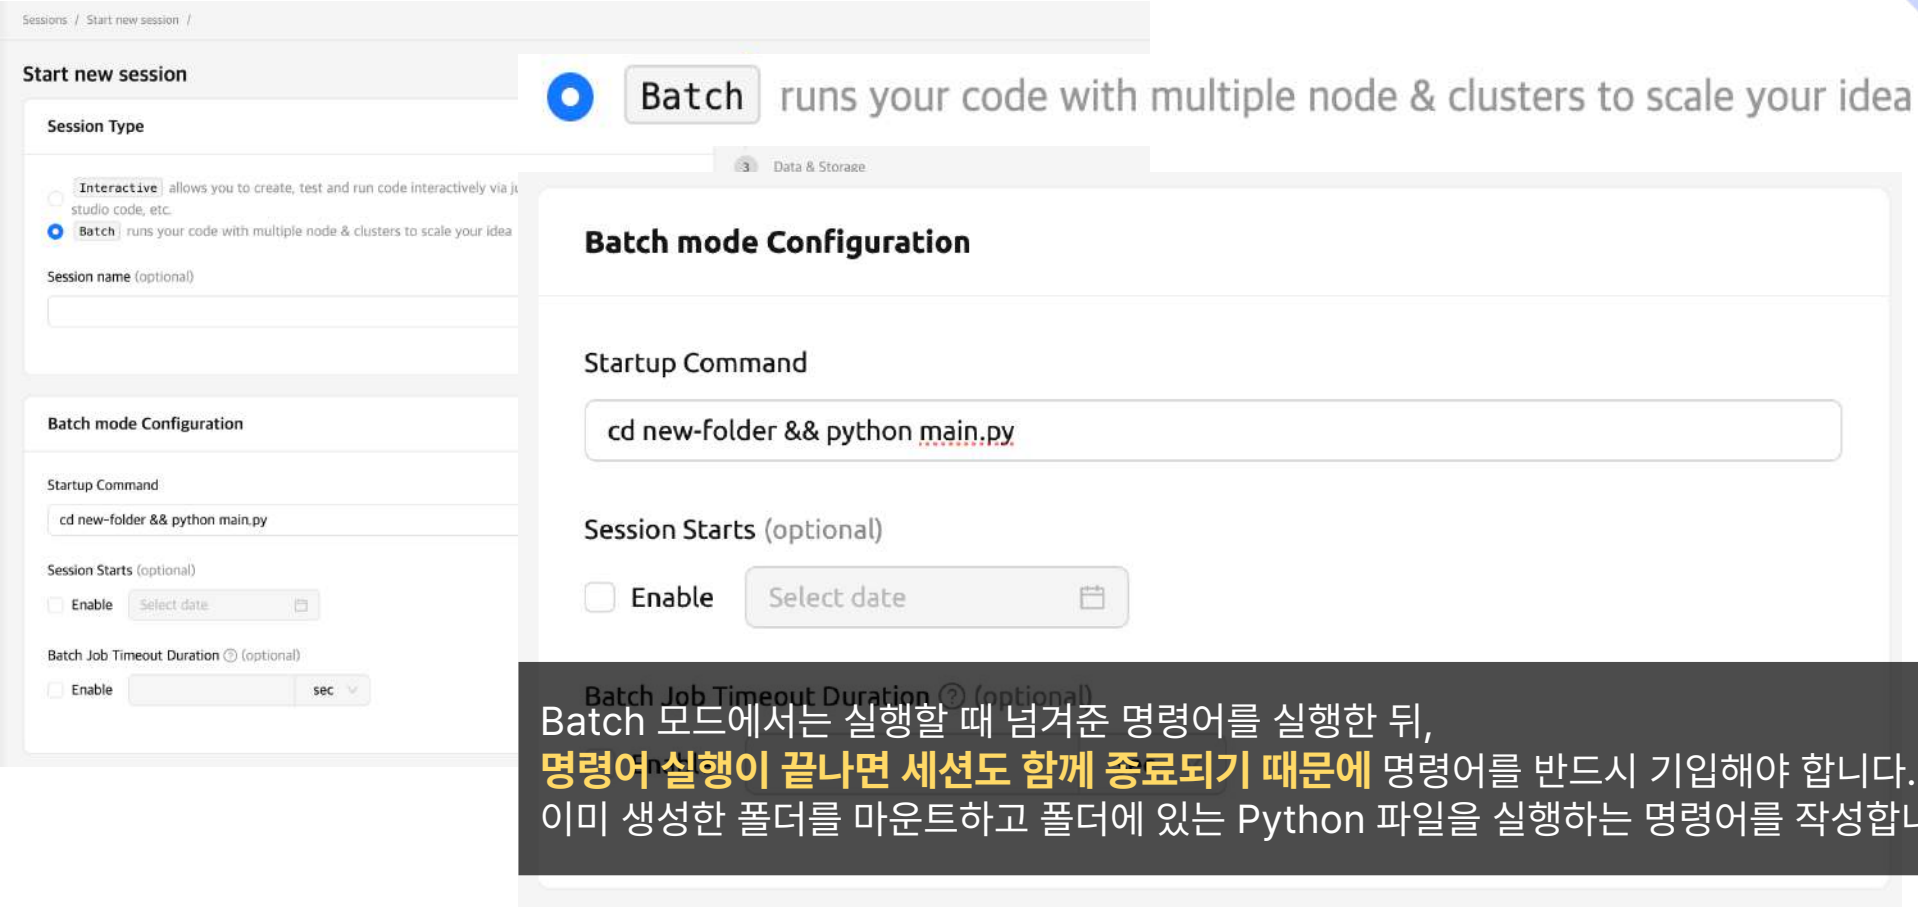

Batch 모드에서는 실행할 때 넘겨준 명령어를 실행한 뒤,
명령어 실행이 끝나면 세션도 함께 종료되기 때문에 명령어를 반드시 기입해야 합니다.
이미 생성한 폴더를 마운트하고 폴더에 있는 Python 파일을 실행하는 명령어를 작성합니다.

세션 : 세션 시작 - 단일 노드 세션

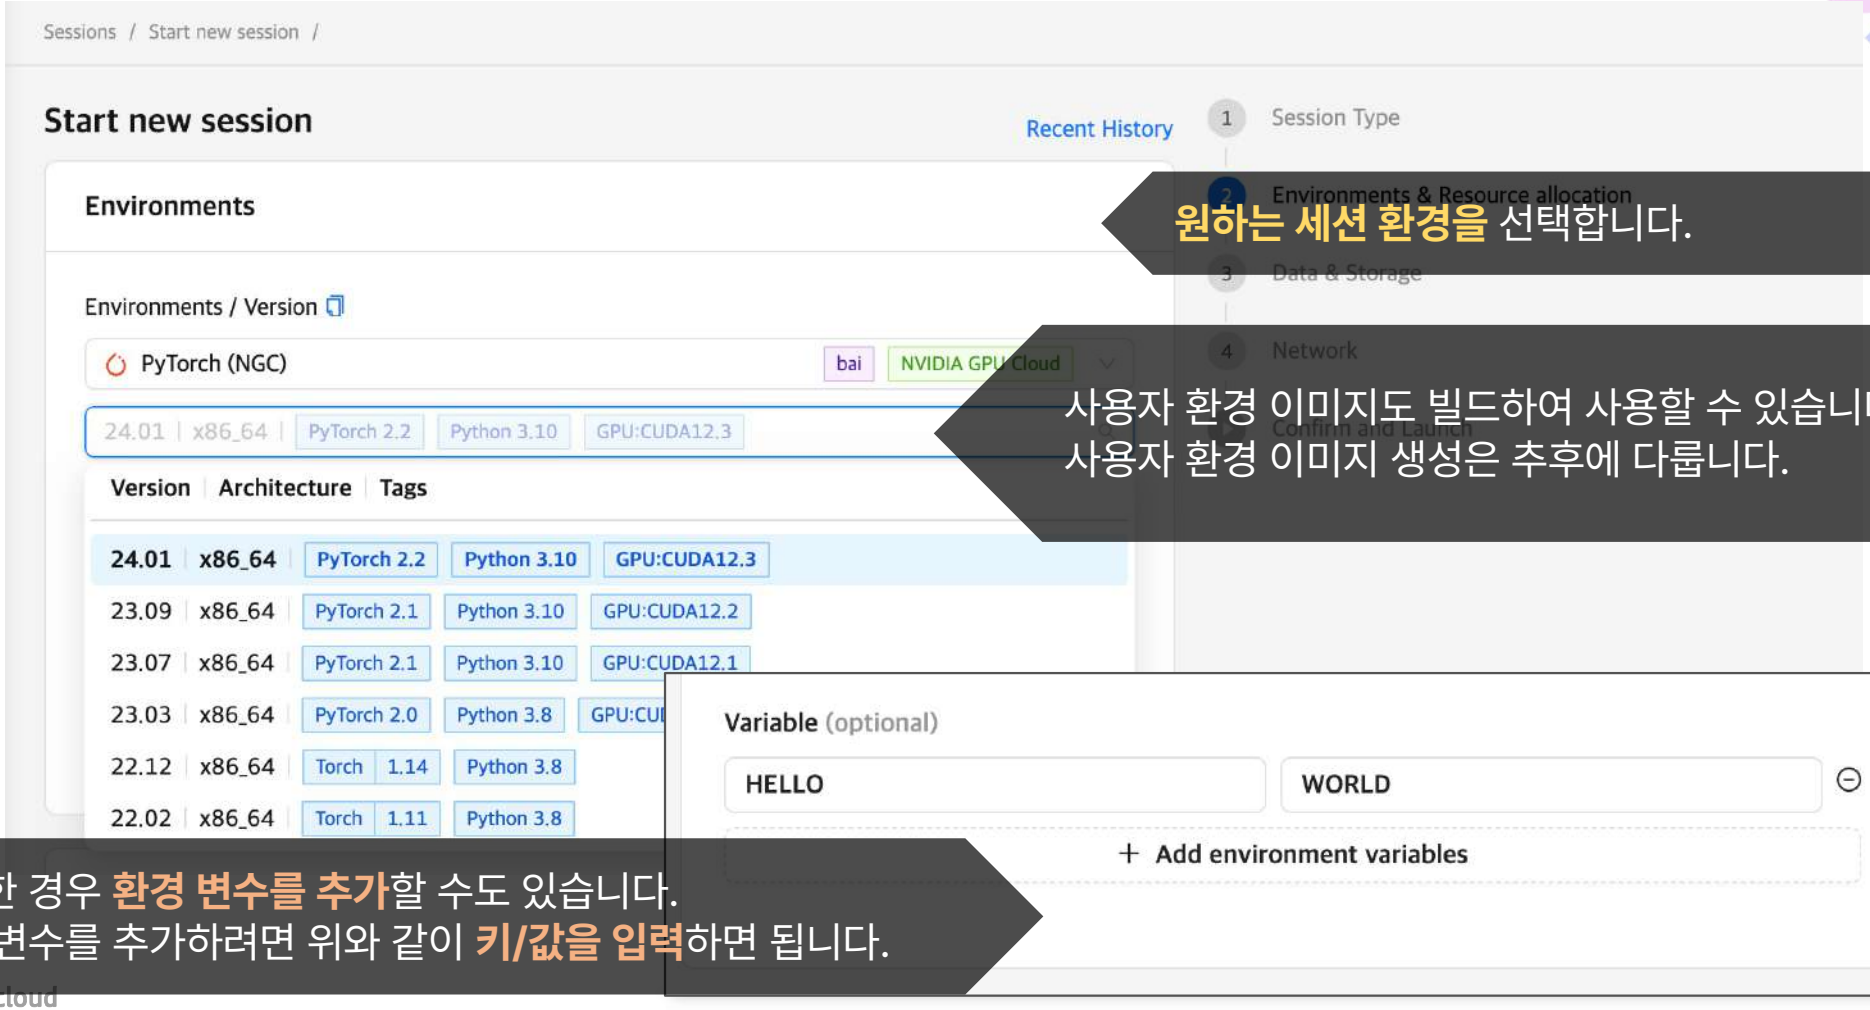

원하는 세션 환경을 선택합니다.

사용자 환경 이미지도 빌드하여 사용할 수 있습니다.
사용자 환경 이미지 생성은 추후에 다룹니다.

필요한 경우 **환경 변수를 추가**할 수도 있습니다.
환경 변수를 추가하려면 위와 같이 **키/값을 입력**하면 됩니다.

세션 : 세션 시작 - 단일 노드 세션

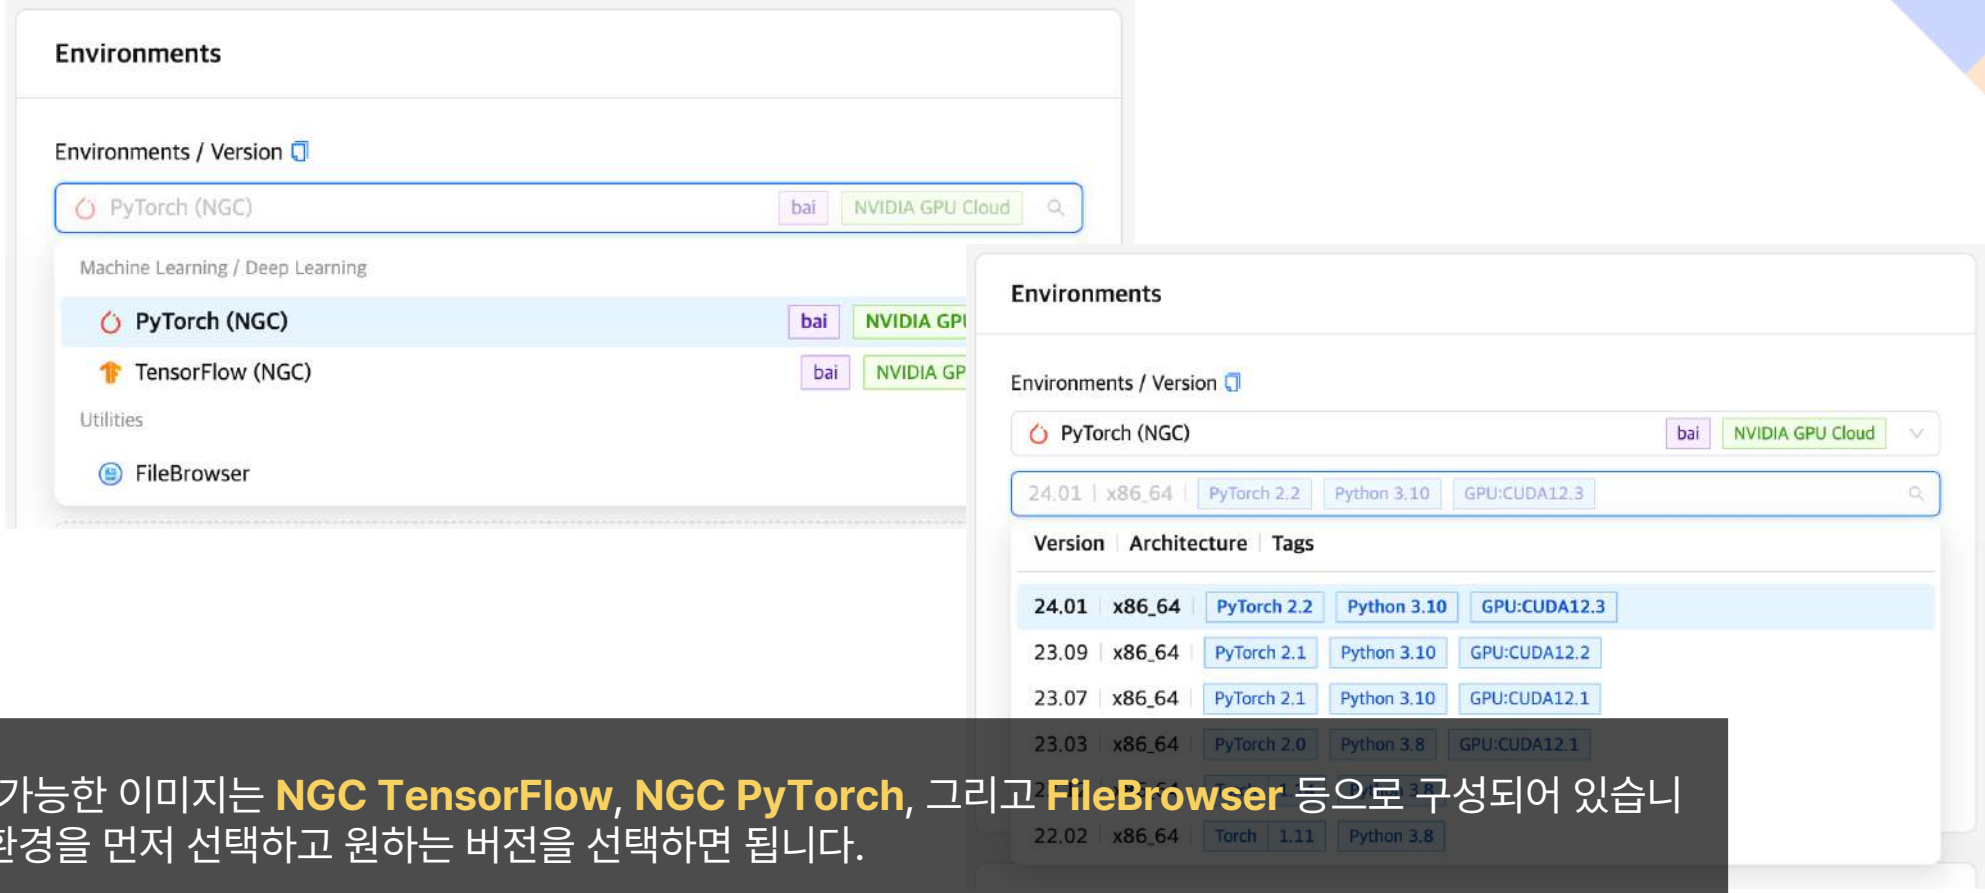

실행가능한 이미지는 **NGC TensorFlow**, **NGC PyTorch**, 그리고 **FileBrowser** 등으로 구성되어 있습니다. 환경을 먼저 선택하고 원하는 버전을 선택하면 됩니다.

세션 : 세션 시작 - 단일 노드 세션

연산 세션을 생성하기 위해서
자원 그룹을 선택합니다.
(각 자원 그룹에 따라 자원은 다르게 할당될 수 있습니다.)

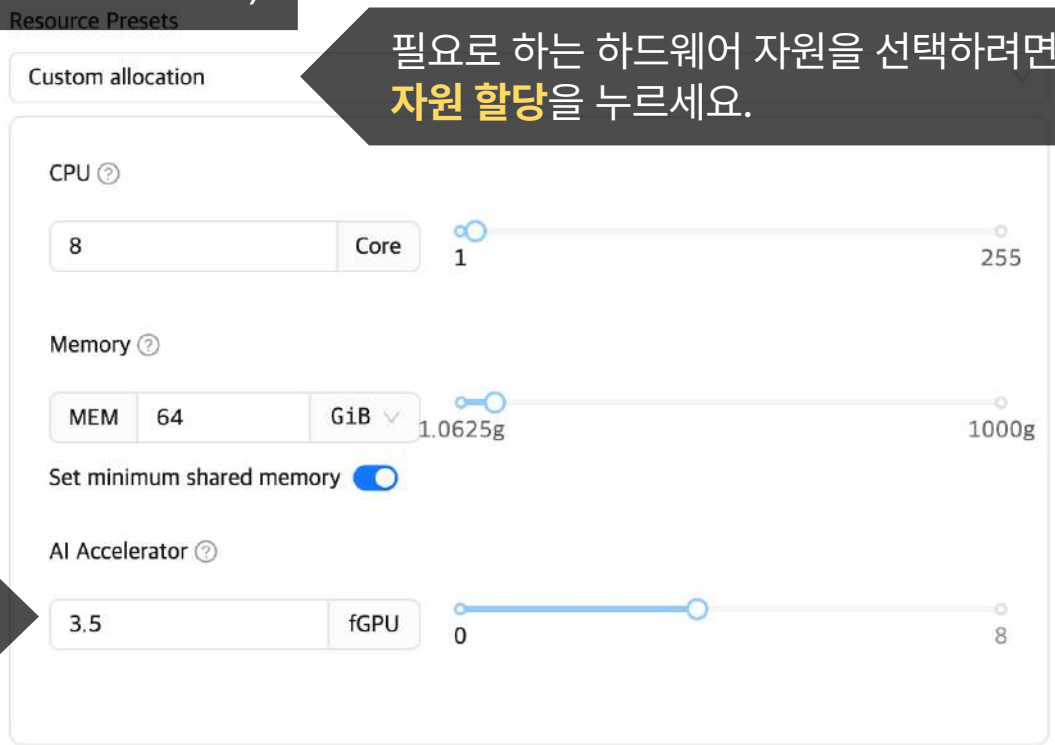

필요로 하는 하드웨어 자원을 선택하려면
자원 할당을 누르세요.

사용자 설정 자원 할당 섹션에서 자원을
자유롭게 할당할 수 있습니다.
(※ 정책적으로 제한된 한도 내에서만 가능합니다.)

kt cloud CLOUD

lablup

세션 : 세션 시작 - 단일 노드 세션

마운트 할 폴더를 누르고 **생성한 폴더를 선택**합니다.
선택된 폴더는 세션의 `/home/work/` 하위에 마운트 됩니다.

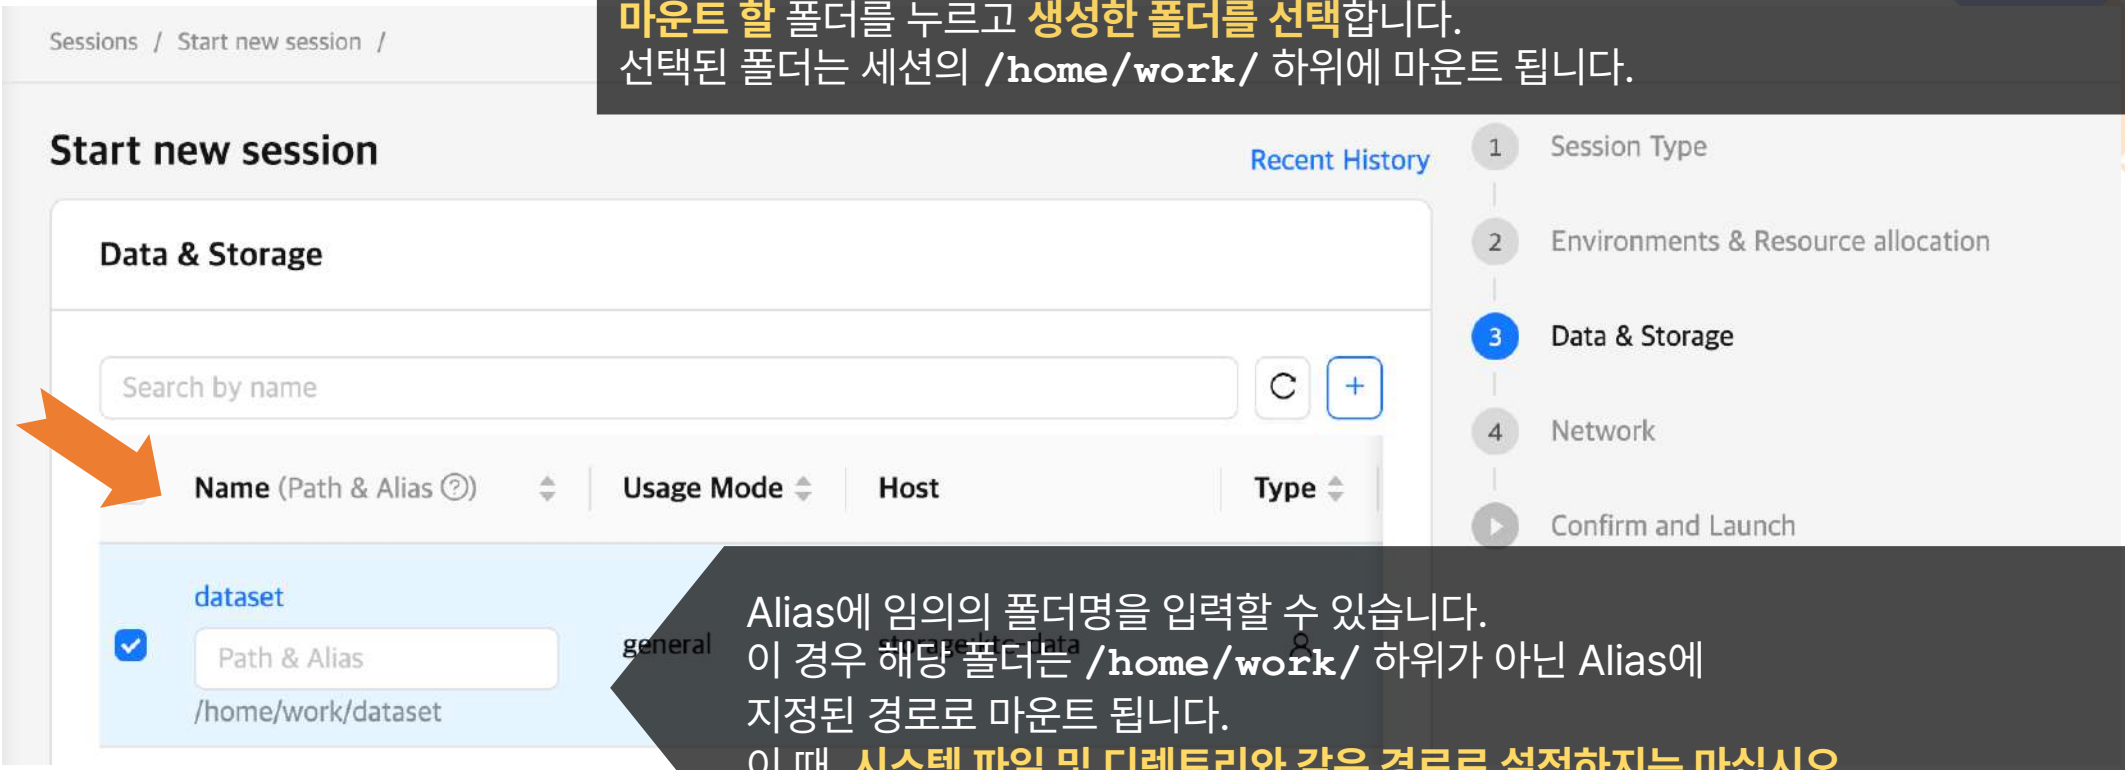

Alias에 임의의 폴더명을 입력할 수 있습니다.
이 경우 해당 폴더는 `/home/work/` 하위가 아닌 Alias에
지정된 경로로 마운트 됩니다.
이 때, **시스템 파일 및 디렉토리와 같은 경로로 설정하지는 마십시오.**

다수의 폴더를 생성했다면, 여러 폴더들을 동시에 선택하고 마운트 할 수 있습니다.

세션 : 세션 시작 - 단일 노드 세션

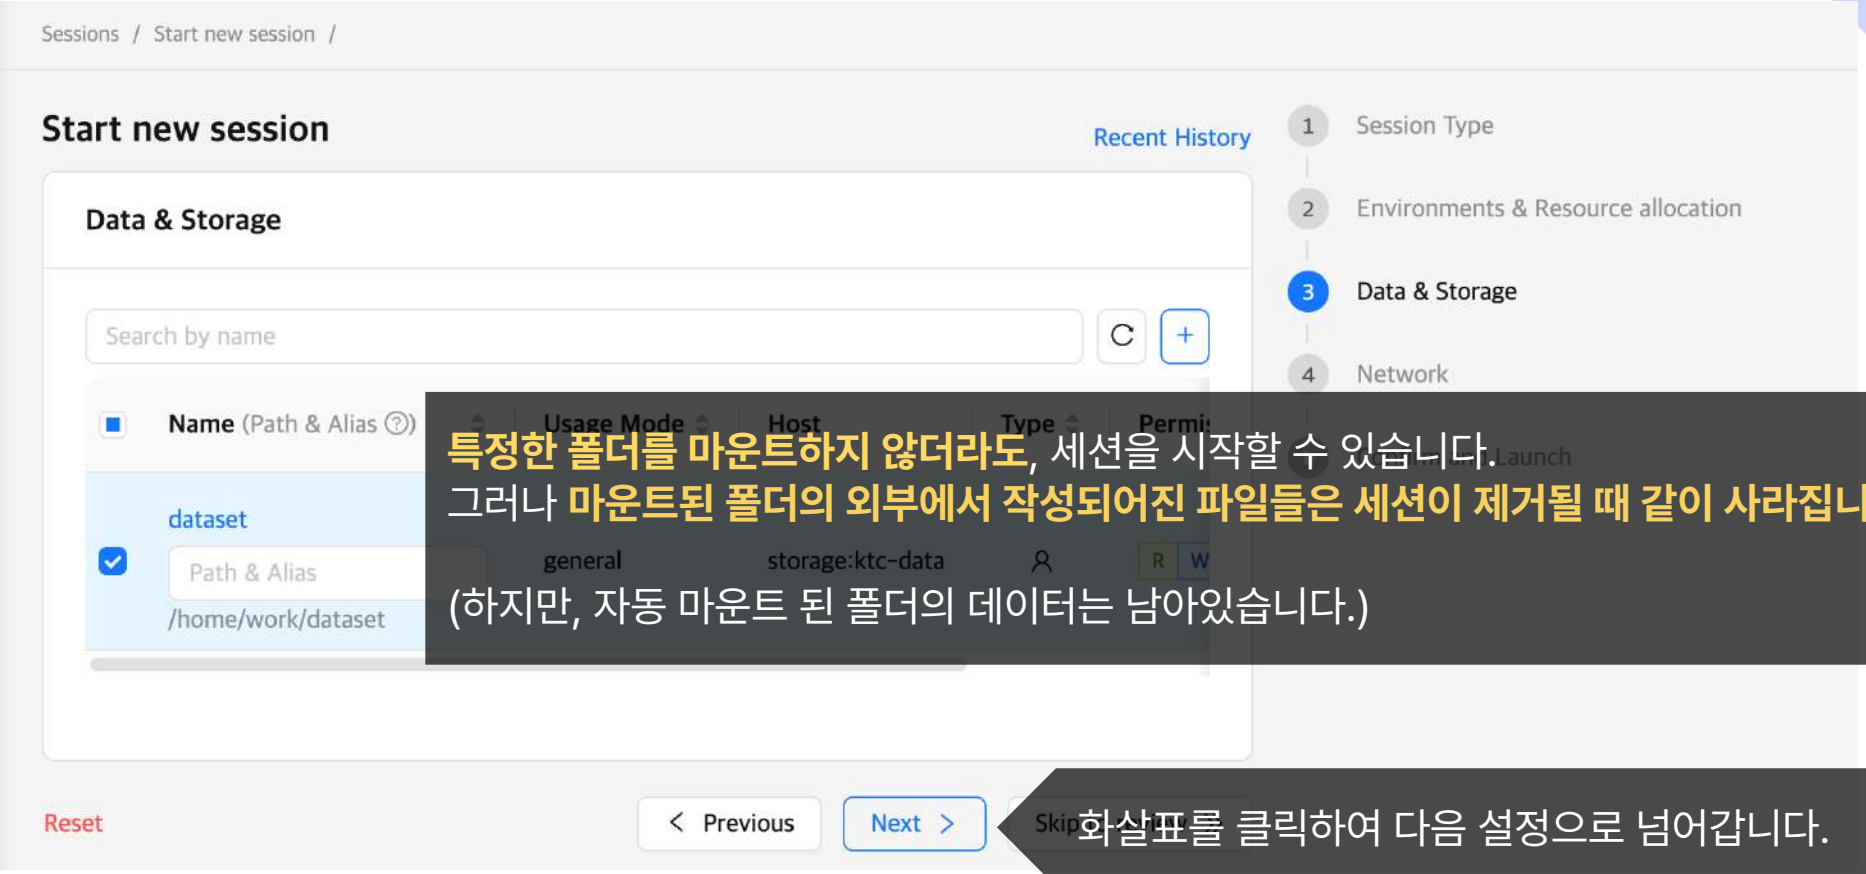

특정한 폴더를 마운트하지 않더라도, 세션을 시작할 수 있습니다.
그러나 **마운트된 폴더의 외부에서 작성되어진 파일들은 세션이 제거될 때 같이 사라집니다.**
(하지만, 자동 마운트 된 폴더의 데이터는 남아있습니다.)

화살표를 클릭하여 다음 설정으로 넘어갑니다.

세션 : 세션 시작 - 단일 노드 세션

세션에서는 기본적으로 **세션 내 앱 실행시 특정 포트만 오픈**하고 있습니다.
그외에 다른 포트를 열고 싶은 경우 1025 ~ 65535 이내 값을 입력하면 해당 숫자에 해당하는 포트를 열 수 있습니다.

세션을 실행할 때 필수요소가 아니므로 이 부분은 **특별한 사용 용도가 없다면 비워두시는걸 권장합니다**.

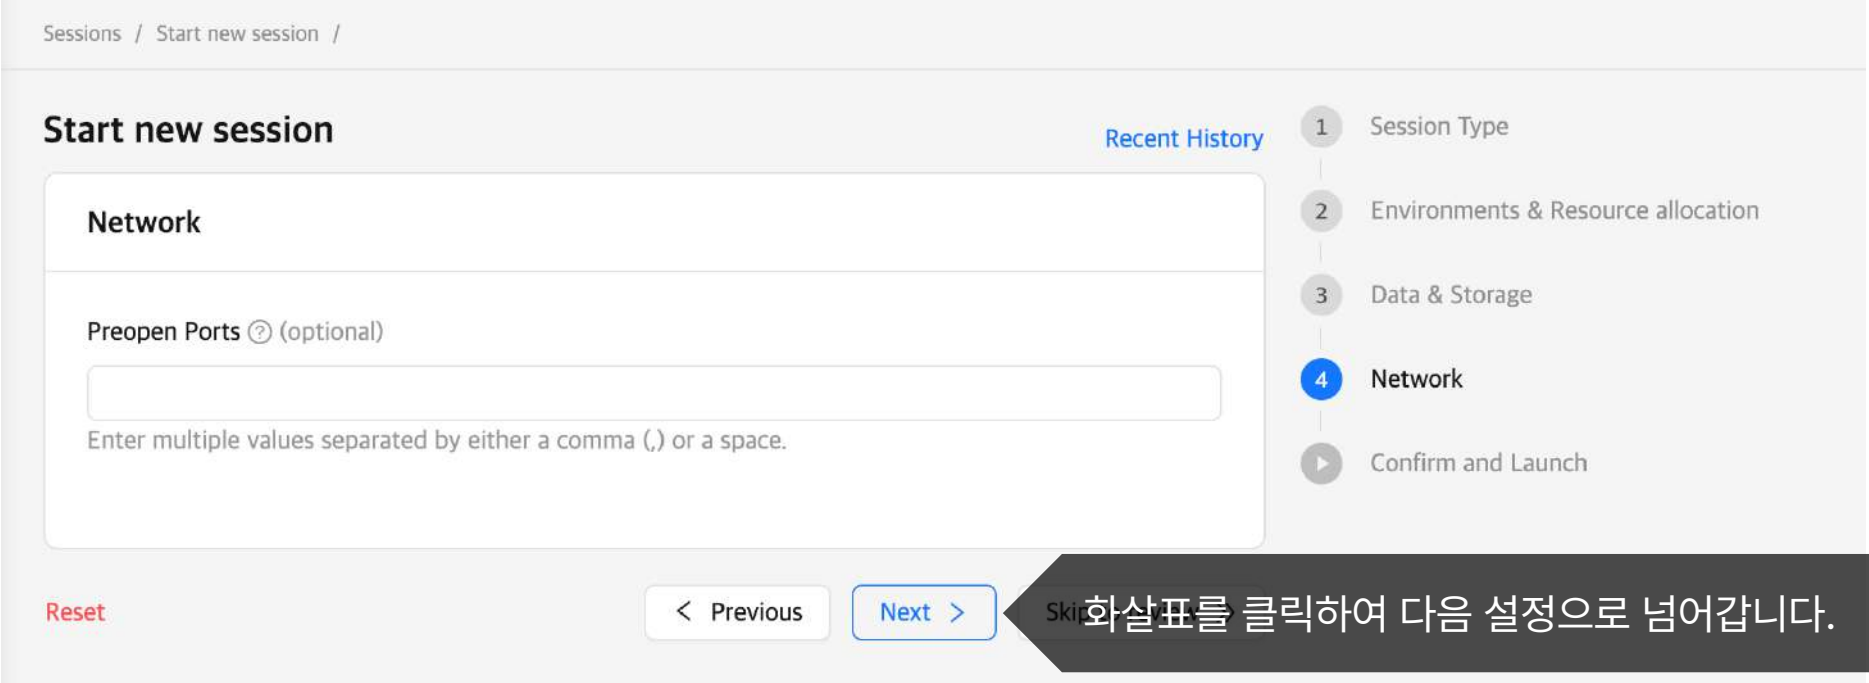

화살표를 클릭하여 다음 설정으로 넘어갑니다.

세션 : 세션 시작 - 단일 노드 세션

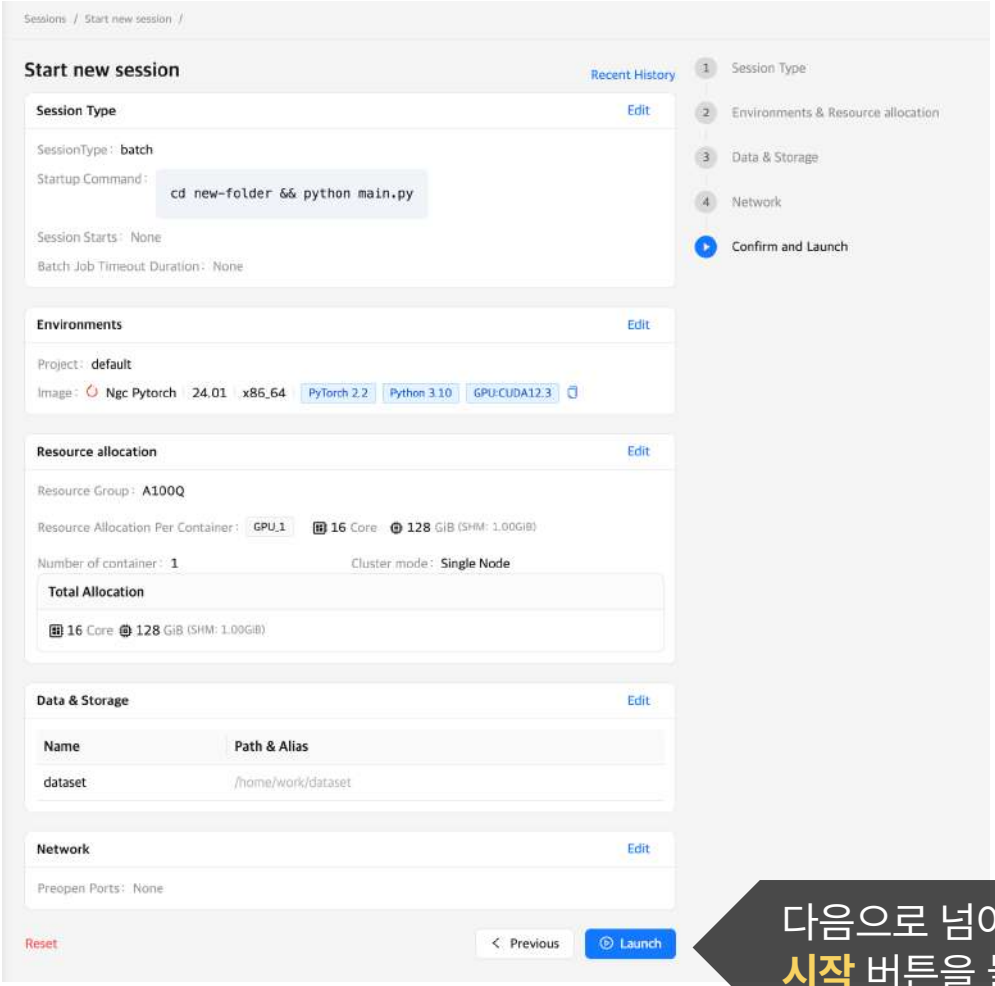

다음으로 넘어와 세부 환경 설정 확인 후,
시작 버튼을 눌러 **세션을 생성합니다**.

세션 : 세션 시작 - 다중 노드 세션

NOTE
다중노드 기능은 1PF 할당한 사용자에 한해서만 사용하는 것을 권장합니다.

단일 노드 세션 생성과 크게 다르지 않습니다.
동일한 방법으로 세션 생성을 시작하고 세션 런처의 2번째 페이지에서 **클러스터 모드 설정**을 변경합니다.

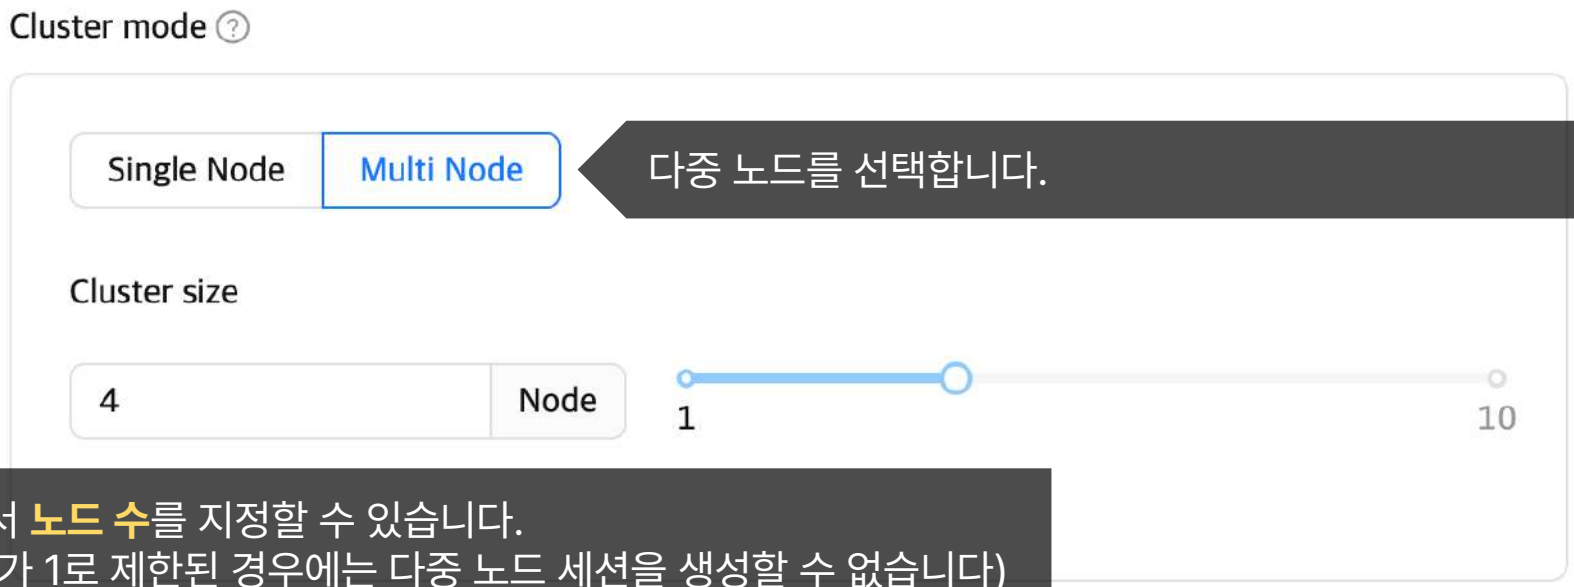

다중 노드를 선택합니다.

클러스터 크기에서 **노드 수**를 지정할 수 있습니다.
(※ 클러스터 크기가 1로 제한된 경우에는 다중 노드 세션을 생성할 수 없습니다)

세션 : 세션 시작 - 다중 노드 세션

세션을 시작한 후, **환경 변수를 "export"** 명령으로 확인할 수 있습니다.
계산환경 이미지와 다양한 환경변수, 클러스터 호스트 등을 볼 수 있습니다.

```
work@main1[my-session]:~$ export
declare -x BACKENDAI_ACCESS_KEY="[illegible]"
declare -x BACKENDAI_CLUSTER_HOST="main1"
declare -x BACKENDAI_CLUSTER_HOSTS="sub1,main1"
declare -x BACKENDAI_CLUSTER_IDX="1"
declare -x BACKENDAI_CLUSTER_LOCAL_RANK="0"
declare -x BACKENDAI_CLUSTER_REPLICAS="main:1,sub:1"
```

```
work@main1[my-session]:~$ ssh sub1
Warning: Permanently added '[sub1]:2200,[10.64.20.132]:2200' (
work@sub1[my-session]:~$
[0] 0:*
```

다중 노드 세션을 생성한 경우, 클러스터 호스트를 확인하고 "**ssh <호스트 이름>**"
으로 노드를 전환할 수 있습니다.

세션 : 세션 시작 - 다중 노드 세션 (예시 : 노드 8개로 DeepSpeed 실행)

```
sub1: sub1:931:1990 [1] NCCL INFO Connected all trees
sub1: sub1:931:1990 [1] NCCL INFO 32 coll channels, 32 p2p channels, 32 p2p channels per peer
sub1: sub1:931:1990 [1] NCCL INFO comm 0x7fb3ac008fb0 rank 0 nranks 1 cudaDev 1 busId 48000 - Init COMPLETE
sub1: sub1:937:1983 [7] NCCL INFO Connected all rings
sub1: sub1:937:1983 [7] NCCL INFO Connected all trees
sub1: sub1:937:1983 [7] NCCL INFO 32 coll channels, 32 p2p channels, 32 p2p channels per peer
sub1: sub1:937:1983 [7] NCCL INFO comm 0x7f61f8008fb0 rank 0 nranks 1 cudaDev 7 busId cd000 - Init COMPLETE
sub1: sub1:933:1992 [3] NCCL INFO Connected all rings
sub1: sub1:933:1992 [3] NCCL INFO Connected all trees
sub1: sub1:933:1992 [3] NCCL INFO 32 coll channels, 32 p2p channels, 32 p2p channels per peer
sub1: sub1:932:1995 [2] NCCL INFO Connected all rings
sub1: sub1:932:1995 [2] NCCL INFO Connected all trees
sub1: sub1:932:1995 [2] NCCL INFO 32 coll channels, 32 p2p channels, 32 p2p channels per peer
sub1: sub1:932:1995 [2] NCCL INFO comm 0x7f0a04008fb0 rank 0 nranks 1 cudaDev 2 busId 4c000 - Init COMPLETE
sub1: sub1:933:1992 [3] NCCL INFO comm 0x7f824c008fb0 rank 0 nranks 1 cudaDev 3 busId 88000 - Init COMPLETE
sub1: sub1:935:1988 [5] NCCL INFO Connected all rings
sub1: sub1:935:1988 [5] NCCL INFO Connected all trees
sub1: sub1:935:1988 [5] NCCL INFO 32 coll channels, 32 p2p channels, 32 p2p channels per peer
sub1: sub1:934:1994 [4] NCCL INFO Connected all rings
sub1: sub1:934:1994 [4] NCCL INFO Connected all trees
sub1: sub1:934:1994 [4] NCCL INFO 32 coll channels, 32 p2p channels, 32 p2p channels per peer
sub1: sub1:935:1988 [5] NCCL INFO comm 0x7f2798008fb0 rank 0 nranks 1 cudaDev 5 busId c8000 - Init COMPLETE
sub1: sub1:934:1994 [4] NCCL INFO comm 0x7f893c008fb0 rank 0 nranks 1 cudaDev 4 busId 8c000 - Init COMPLETE
sub1: sub1:936:1996 [6] NCCL INFO Connected all rings
sub1: sub1:936:1996 [6] NCCL INFO Connected all trees
sub1: sub1:936:1996 [6] NCCL INFO 32 coll channels, 32 p2p channels, 32 p2p channels per peer
sub1: sub1:936:1996 [6] NCCL INFO comm 0x7f417089acf0 rank 0 nranks 1 cudaDev 6 busId cc000 - Init COMPLETE
sub1: [after dataloaders are built] datetime: 2023-04-05 13:25:11
sub1: done with setup ...
sub1: training ...
main1: time (ms) | model-and-optimizer-setup: 59006.50 | train/valid/test-data-iterators-setup: 1488.71
sub1: [before the start of training step] datetime: 2023-04-05 13:25:11
sub1: [2023-04-05 13:25:11,761] [INFO] [checkpointing.py:553:forward] Activation Checkpointing Information
sub1: [2023-04-05 13:25:11,762] [INFO] [checkpointing.py:554:forward] ----Partition Activations False, CPU CHECKPOINT
ING False
sub1: [2023-04-05 13:25:11,762] [INFO] [checkpointing.py:557:forward] ----contiguous Memory Checkpointing False with
36 total layers
sub1: [2023-04-05 13:25:11,762] [INFO] [checkpointing.py:560:forward] ----Synchronization False
sub1: [2023-04-05 13:25:11,762] [INFO] [checkpointing.py:561:forward] ----Profiling time in checkpointing False
sub1: [2023-04-05 13:25:23,019] [INFO] [loss_scaler.py:180:update_scale] [deepspeed] OVERFLOW! Rank 0 Skipping step.
Attempted loss scale: 4294967296, but hysteresis is 2. Reducing hysteresis to 1
sub1: [2023-04-05 13:25:23,020] [INFO] [logging.py:93:log_dist] [Rank 0] rank=0 time (ms) | forward_microstep: 4082.3
7 | backward_microstep: 7173.24 | backward_inner_microstep: 7004.29 | backward_allreduce_microstep: 168.89 | step_mic
rostep: 2.75
sub1: [2023-04-05 13:25:23,020] [INFO] [logging.py:93:log_dist] [Rank 0] rank=0 time (ms) | forward: 4082.35 | backwa
rd: 7173.23 | backward_inner: 7004.28 | backward_allreduce: 168.89 | step: 2.75
sub1: [Rank 0] (after 1 iterations) memory (MB) | allocated: 20478.66796875 | max allocated: 30163.41552734375 | rese
rved: 32778.0 | max reserved: 32778.0
main1:  iteration        1/       6 | consumed samples:         1024 | consumed tokens:       262144 | elapsed time p
er iteration (ms): 11291.5 | learning rate: 6.000E-05 | global batch size:  1024 | lm loss: 1.087584E+01 | loss scale
: 4294967296.0 | actual seqlen:   256 | number of skipped iterations:   0 | number of nan iterations:   0 | samples p
er second: 90.687 | TFLOPs: 86.80 |
main1: time (ms) | forward-compute: 4112.29 | backward-compute: 7170.64 | backward-embedding-all-reduce: 0.01 | optim
izer: 5.64 | batch-generator: 2.26
```

```
+-----------------------------------------------------------------------------+
| NVIDIA-SMI 510.39.01    Driver Version: 510.39.01    CUDA Version: 11.6     |
|-------------------------------+----------------------+----------------------+
| GPU  Name        Persistence-M| Bus-Id        Disp.A | Volatile Uncorr. ECC |
| Fan  Temp  Perf  Pwr:Usage/Cap|         Memory-Usage | GPU-Util  Compute M. |
|                               |                      |               MIG M. |
|===============================+======================+======================|
|   0  CUDA GPU            On   | 00000000:0B:00.0 Off |                    Off |
| N/A   43C    P0    64W / 250W |  34339MiB / 40960MiB |     99%      Default |
|                               |                      |             Disabled |
|-------------------------------+----------------------+----------------------|
|   1  CUDA GPU            On   | 00000000:48:00.0 Off |                    Off |
| N/A   41C    P0    56W / 250W |  34387MiB / 40960MiB |     99%      Default |
|                               |                      |             Disabled |
|-------------------------------+----------------------+----------------------|
|   2  CUDA GPU            On   | 00000000:4C:00.0 Off |                    Off |
| N/A   42C    P0   106W / 250W |  34347MiB / 40960MiB |     99%      Default |
|                               |                      |             Disabled |
|-------------------------------+----------------------+----------------------|
|   3  CUDA GPU            On   | 00000000:88:00.0 Off |                    0 |
| N/A   45C    P0    66W / 250W |  34427MiB / 40960MiB |     99%      Default |
|                               |                      |             Disabled |
|-------------------------------+----------------------+----------------------|
|   4  CUDA GPU            On   | 00000000:8C:00.0 Off |                    0 |
| N/A   46C    P0   226W / 250W |  34395MiB / 40960MiB |     99%      Default |
|                               |                      |             Disabled |
|-------------------------------+----------------------+----------------------|
|   5  CUDA GPU            On   | 00000000:C8:00.0 Off |                    0 |
| N/A   43C    P0   251W / 250W |  34379MiB / 40960MiB |     99%      Default |
|                               |                      |             Disabled |
|-------------------------------+----------------------+----------------------|
|   6  CUDA GPU            On   | 00000000:CC:00.0 Off |                    Off |
| N/A   42C    P0    67W / 250W |  34387MiB / 40960MiB |     99%      Default |
|                               |                      |             Disabled |
|-------------------------------+----------------------+----------------------|
|   7  CUDA GPU            On   | 00000000:CD:00.0 Off |                    Off |
| N/A   40C    P0    66W / 250W |  34339MiB / 40960MiB |     99%      Default |
|                               |                      |             Disabled |
+-------------------------------+----------------------+----------------------+

+-----------------------------------------------------------------------------+
| Processes:                                                                  |
|  GPU   GI   CI        PID   Type   Process name                  GPU Memory |
|        ID   ID                                                   Usage      |
|=============================================================================|
|    0   N/A  N/A   4007189      C                                   34291MiB |
|    1   N/A  N/A   4007190      C                                   34339MiB |
|    2   N/A  N/A   4007191      C                                   34299MiB |
|    3   N/A  N/A   4007192      C                                   34379MiB |
|    4   N/A  N/A   4007193      C                                   34347MiB |
|    5   N/A  N/A   4007194      C                                   34331MiB |
|    6   N/A  N/A   4007195      C                                   34339MiB |
|    7   N/A  N/A   4007196      C                                   34291MiB |
+-----------------------------------------------------------------------------+
```

kt cloud CLOUD

lablup

세션 : 세션 활용

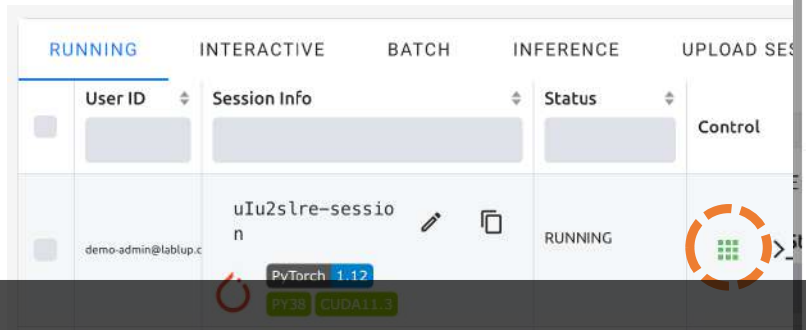

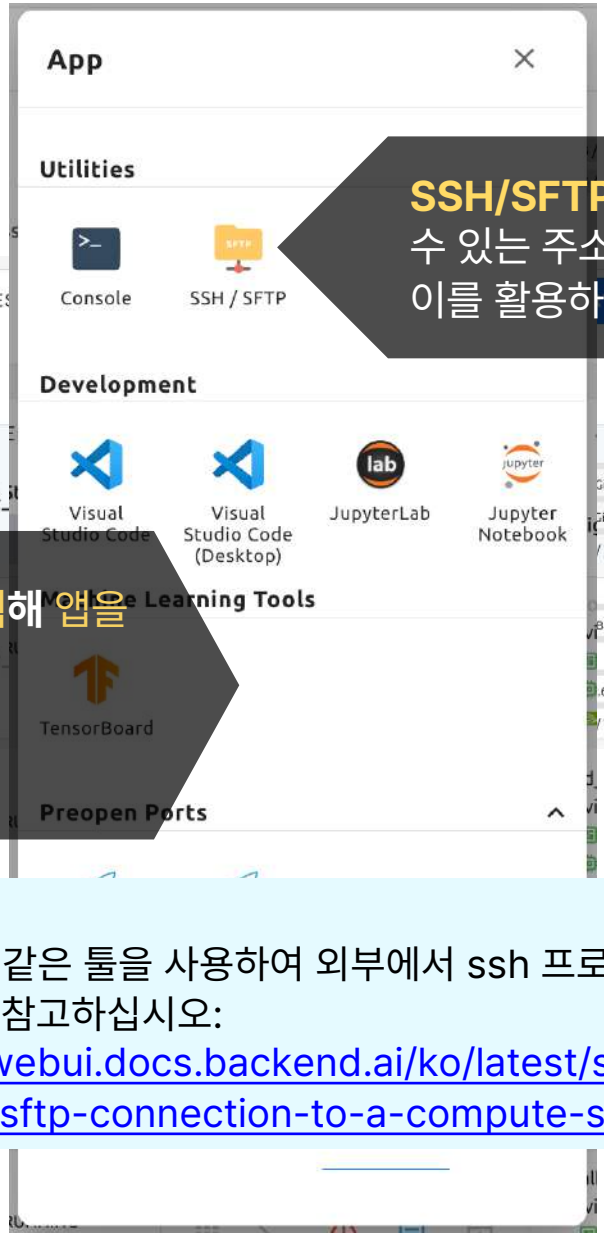

SSH/SFTP 앱을 클릭하면 세션을 로컬에서 접근할 수 있는 주소와 예시가 뜹니다.
이를 활용하여 **로컬 파일을 쉽게 전송**할 수 있습니다.

생성된 세션의 **컨트롤 열에 있는 App 아이콘을 클릭**해 앱을 **실행**할 수 있습니다.
사용하고 있는 환경에 따라 **다양한 앱들을** 시작할 수 있습니다 .

NOTE
Putty 와 같은 툴을 사용하여 외부에서 ssh 프로토콜로 세션에 접속하는 방법은 다음 링크에서 참고하십시오:
https://webui.docs.backend.ai/ko/latest/sftp_to_container/sftp_to_container.html#ssh-sftp-connection-to-a-compute-session

kt cloud CLOUD

lablup

세션 : 세션 활용 – preopen

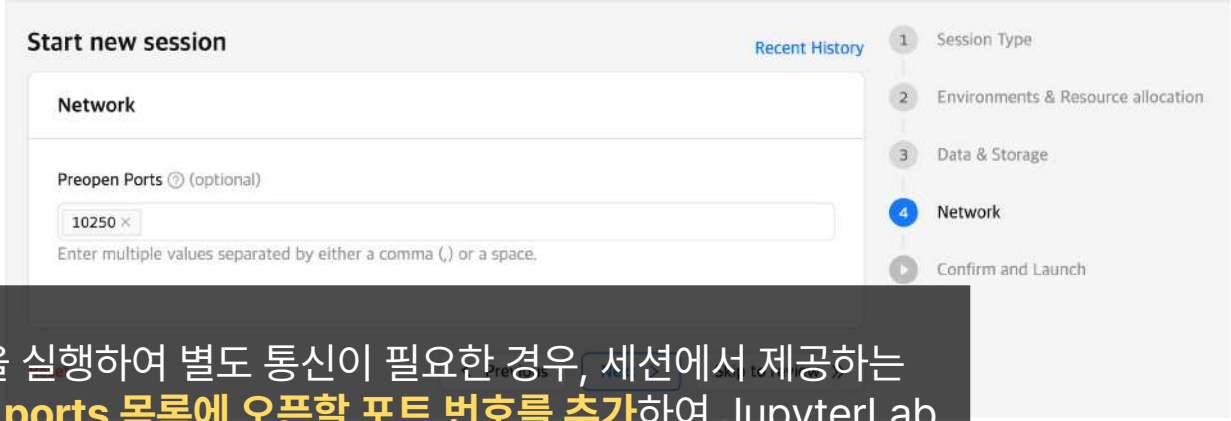

세션에서 웹서버 등을 실행하여 별도 통신이 필요한 경우, 세션에서 제공하는 앱과 같이 **preopen ports 목록에 오픈할 포트 번호를 추가**하여 JupyterLab, VSCode 와 같이 이미지에 임베드된 웹 앱처럼 쓸 수 있습니다.
이 때, 포트번호는 1024 ~ 65535 사이의 번호만 추가할 수 있습니다.

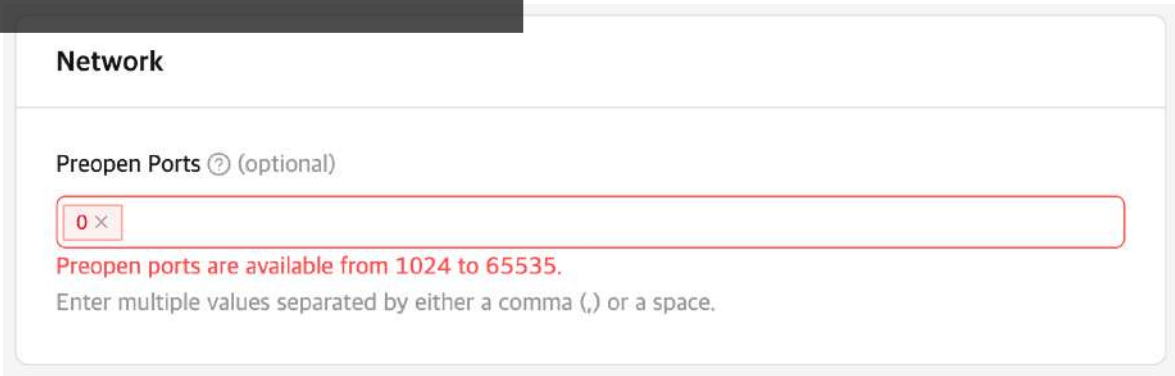

세션 : 세션 활용 – preopen

세션 생성할 때 추가한 **Preopen ports** 목록에 번호가 추가된 걸 확인할 수 있습니다. 클릭하면 포트를 열었을 때 실행되는 웹서버 페이지가 웹앱 형태로 제공됩니다.

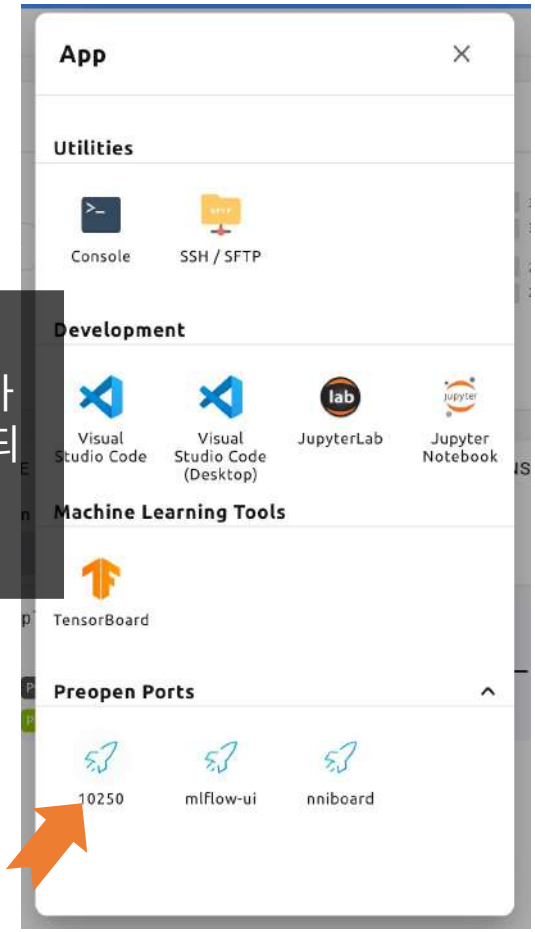

세션 : 세션 활용 - 앱 (JupyterLab의 예시)

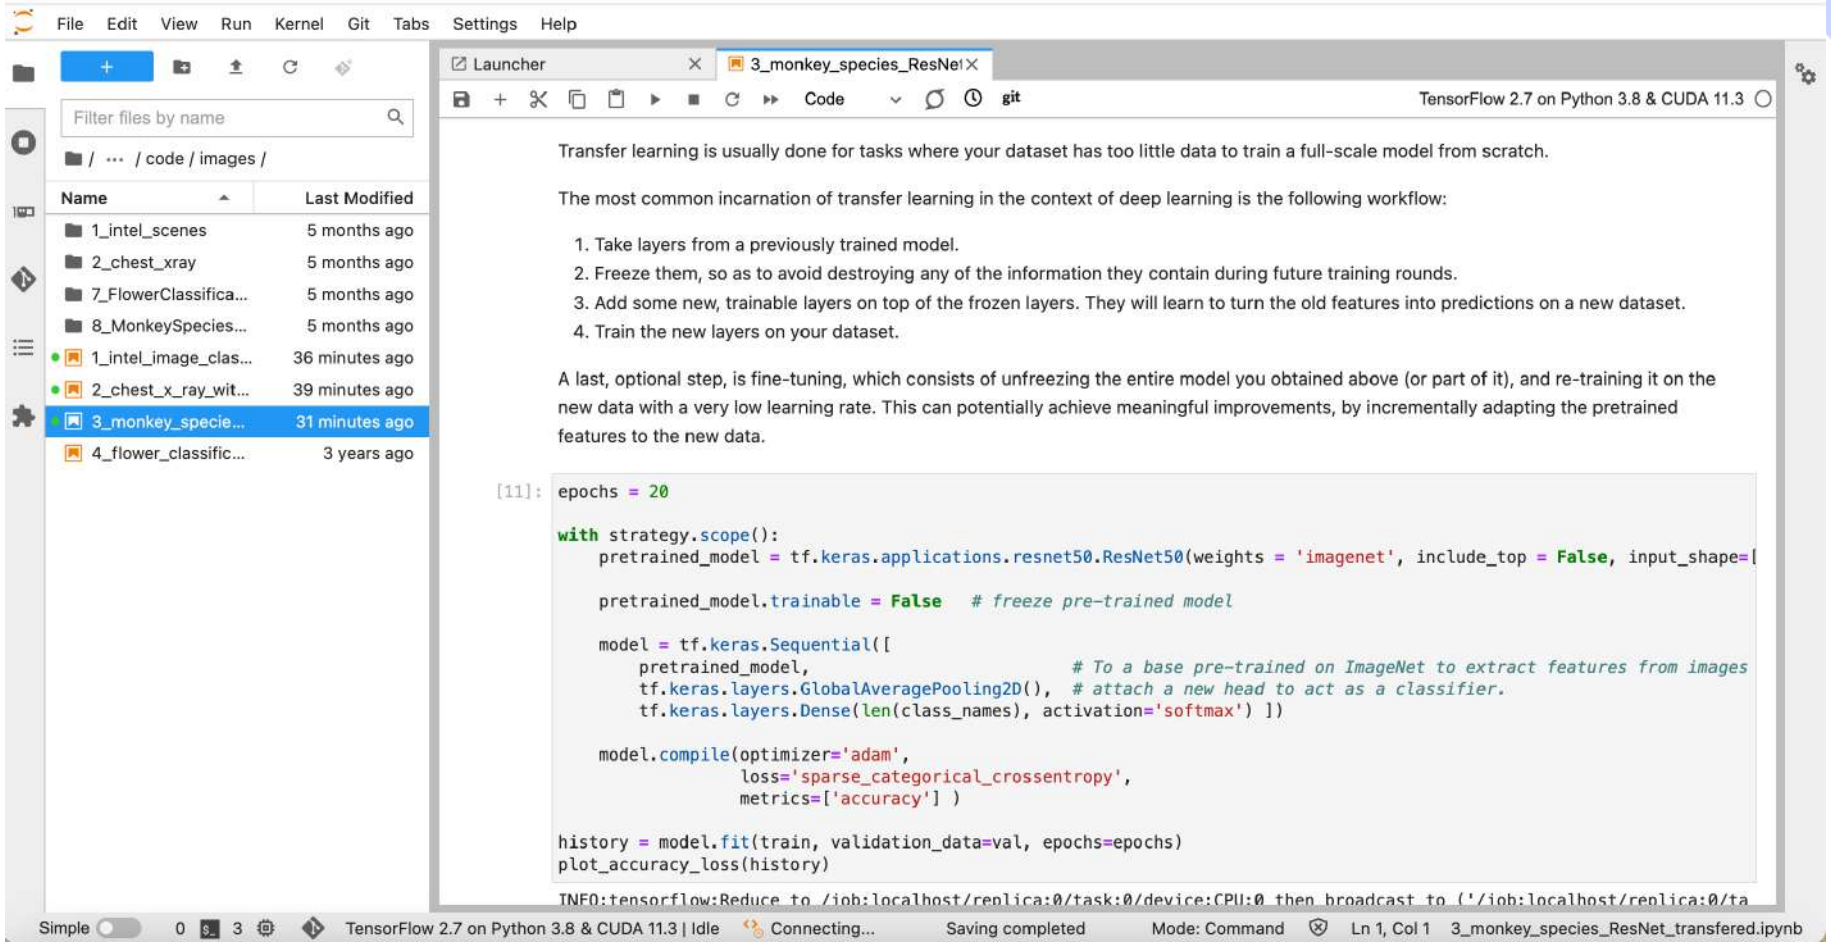

kt cloud CLOUD

lablup

세션 : 세션 활용 - 앱 (VScode의 예시)

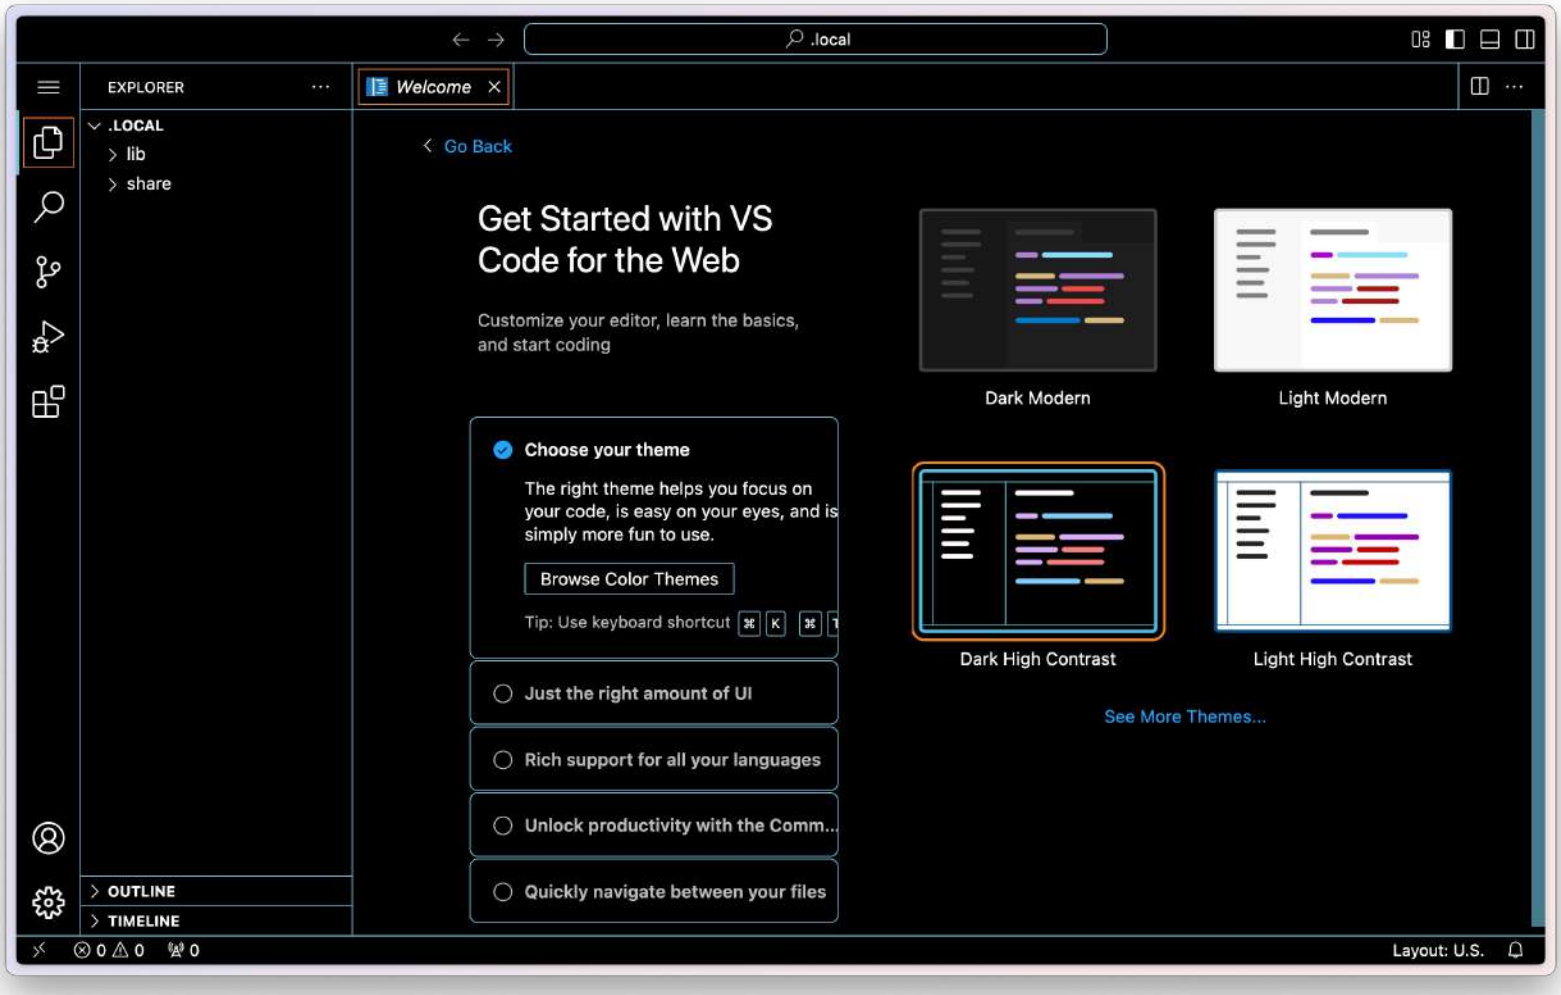

kt cloud CLOUD

lablup

세션 : 세션 종료

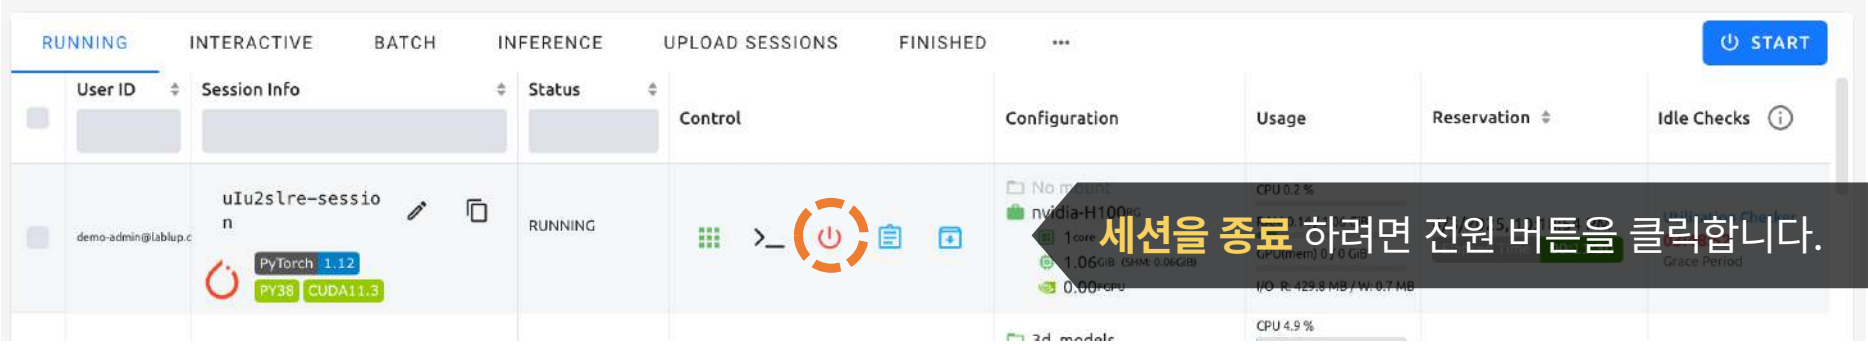
RUNNING
INTERACTIVE
BATCH
INFERENCE
UPLOAD SESSIONS
FINISHED
START
User ID
Session Info
Status
Control
Configuration
Usage
Reservation
Idle Checks
uIu2slre-sessio
n
RUNNING
PyTorch 1.12
PY38
CUDA11.3
nvidia-H100
세션을 종료 하려면 전원 버튼을 클릭합니다.

세션 : 세션 종료

종료 상태의 세션들을 보려면 **종료 탭을 클릭합니다.**

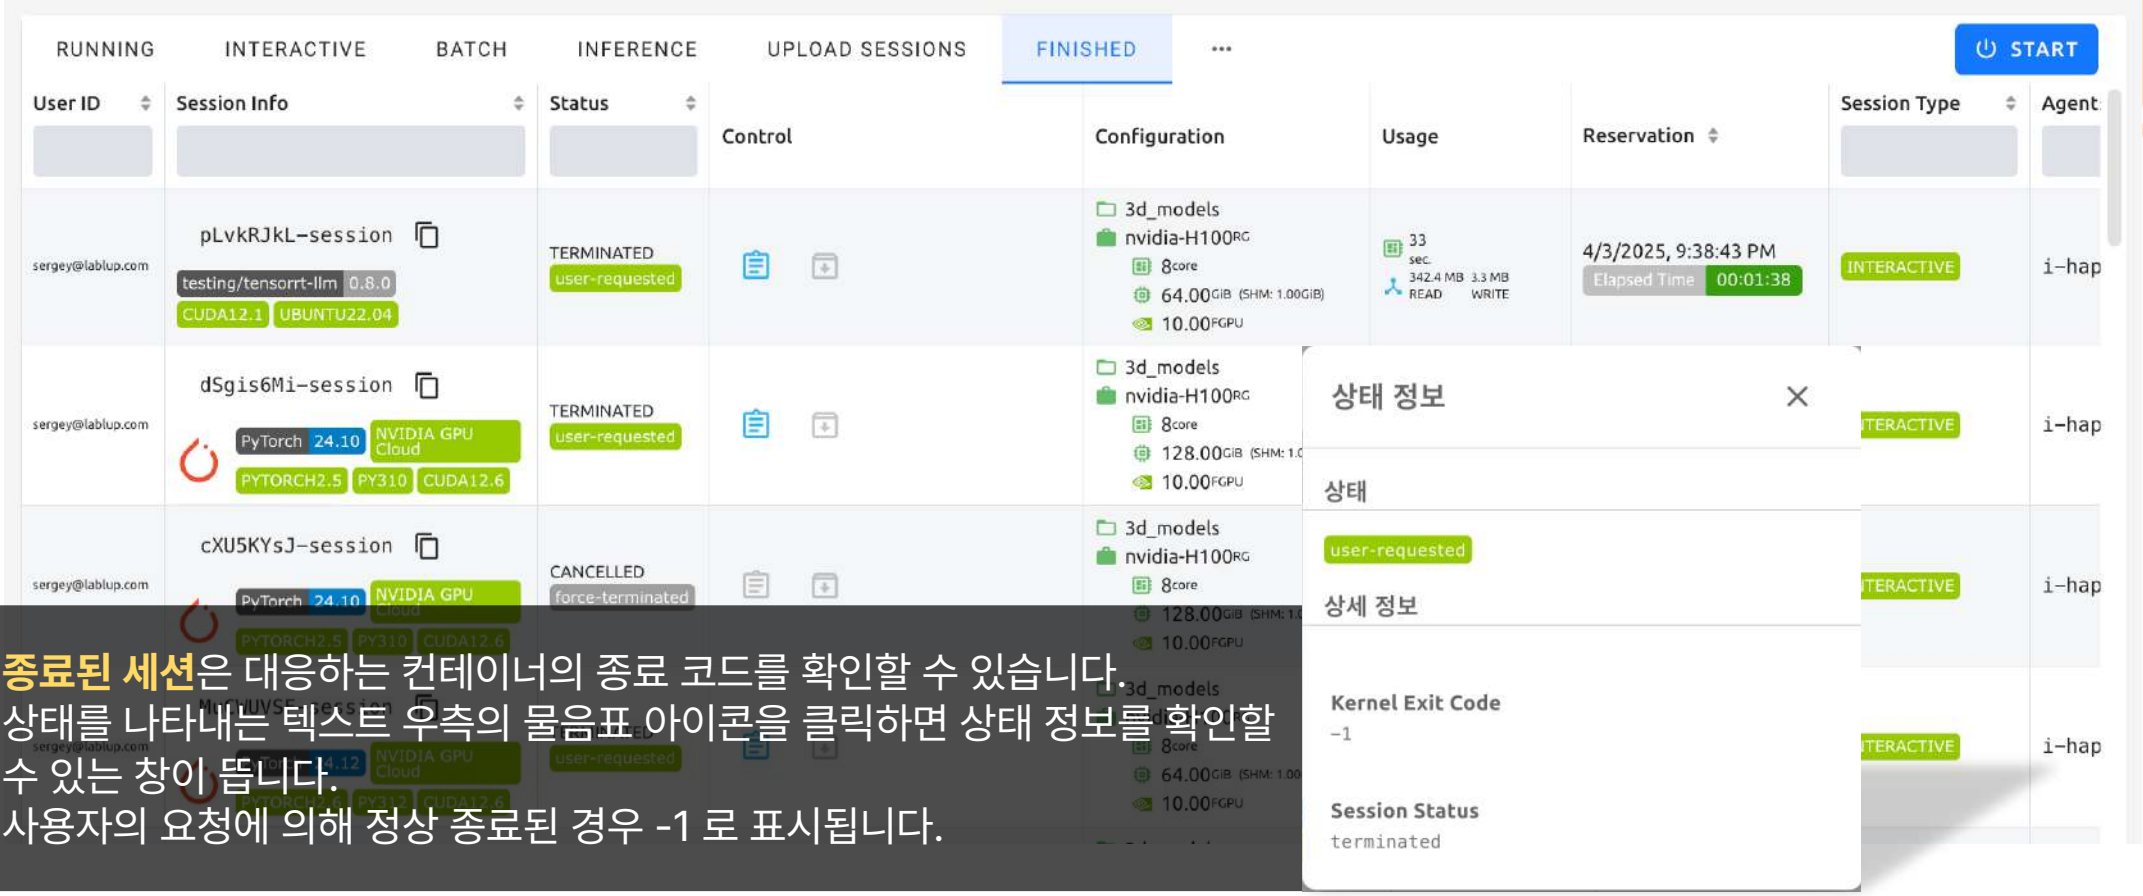

종료된 세션은 대응하는 컨테이너의 종료 코드를 확인할 수 있습니다.
상태를 나타내는 텍스트 우측의 물음표 아이콘을 클릭하면 상태 정보를 확인할 수 있는 창이 뜹니다.
사용자의 요청에 의해 정상 종료된 경우 -1 로 표시됩니다.

kt cloud CLOUD

lablup

세션 : 유휴 상태 검사 (Idle checker)

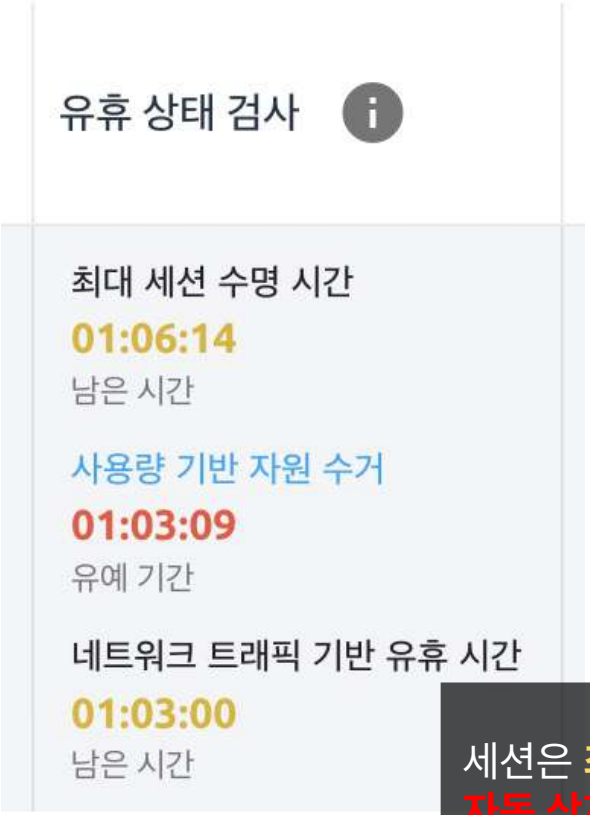

유휴 상태 검사

연산 세션을 자동 삭제하는 세 가지 기준을 제공합니다.

최대 세션 수명 시간

세션 생성 후 이 시간이 지나면 세션을 강제 종료합니다. 세션이 무한으로 실행되는 것을 막을 수 있습니다.

네트워크 트래픽 기반 유휴 시간

사용자(브라우저)와 연산 세션 사이에 이 시간 동안 아무런 네트워크 트래픽이 없을 경우 연산 세션을 삭제합니다. 사용자와 연산 세션 사이의 트래픽은 앱 (터미널, Jupyter 등)을 통해 상호작용(키보드 입력, Jupyter 셀 생성 등) 하는 경우 지속적으로 발생합니다. 만약, 연산 세션을 띄운 채 일정 시간 동안 아무런 입력을 하지 않으면 자동 삭제 조건을 만족하게 됩니다. 연산 세션에서 작업을 수행 중인 프로세스가 있더라도, 사용자와의 상호작용이 없는 경우에는 삭제 대상입니다.

사용량 기반 자원 수거

오직 연산 세션에 할당된 자원의 활용률을 기준으로 연산 세션을 삭제합니다.

- 유예 기간
  자원 사용량 기반 체커를 이 시간 동안 작동하지 않게 합니다. 이 시간이 지나기 전에는 사용량이 적더라도 연산 세션이 삭제되지 않습니다.
- 자원 사용량 기준
  연산 세션의 자원 사용량 기준입니다. 연산 세션의 자원 사용량이 일정 시간 동안 설정된 기준값을 넘지 못하면, 그 세션은 자동으로 삭제됩니다. 예를 들어, CUDA 사용률 기준을 1%로 설정했다면, 일정 시간 동안 1% 미만의 CUDA GPU 사용률을 보이는 연산 세션이 삭제됩니다. 값이 설정되지 않는 자원은 자동 삭제 기준에서 제외됩니다.

세션은 **최대 세션 수명 시간, 네트워크 트래픽 기반 유휴 시간, 사용량 기반 자원 수거**를 기준으로 **자동 삭제**될 수 있습니다.

i 버튼을 누르면 유휴 상태 검사의 자세한 설명을 확인할 수 있습니다.

kt cloud CLOUD

lablup

세션 : 유휴 상태 검사 (Idle checker)

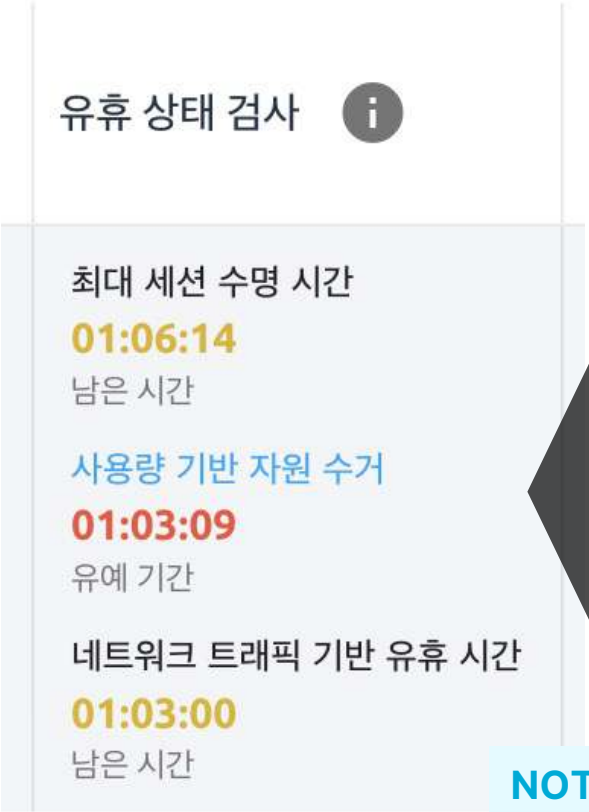

사용량 기반 자원 수거 위에 마우스를 갖다 대면, 현재 **자원 사용률**과 **수거 기준값**을 확인할 수 있습니다.
사용량 기반 자원 수거의 유예 기간 이후, 자원 사용률이 수거 기준값을 넘기지 못하면 **자동 삭제 대상**이 됩니다.

NOTE
본 사업에서는 GPU 사용량 기반으로 동적할당정책(자원회수정책)을 운영하고 있으며,
최근 8 시간 동안의 GPU CUDA utilization 평균 1% 미만인 경우 자원 수거가 진행됩니다.

세션 : 세션 정보 모달

세션에 대한 세부 정보는 **세션 정보 모달**에서도 확인이 가능합니다.
세션 정보 모달은 **세션 리스트**의 **세션 이름을 클릭**해 사용할 수 있습니다.

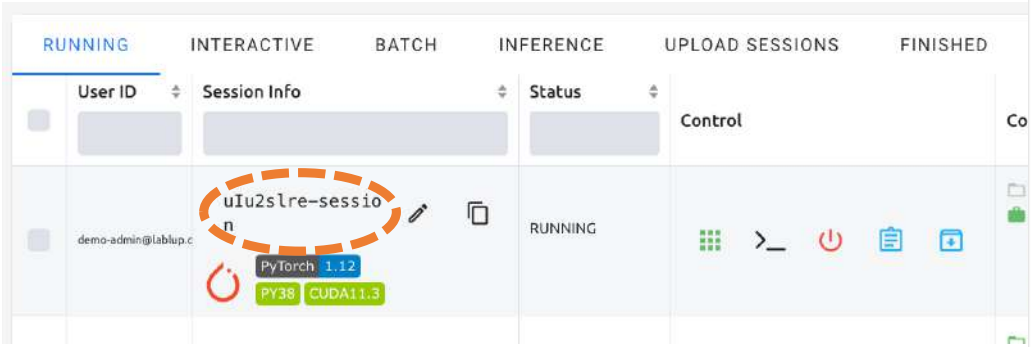

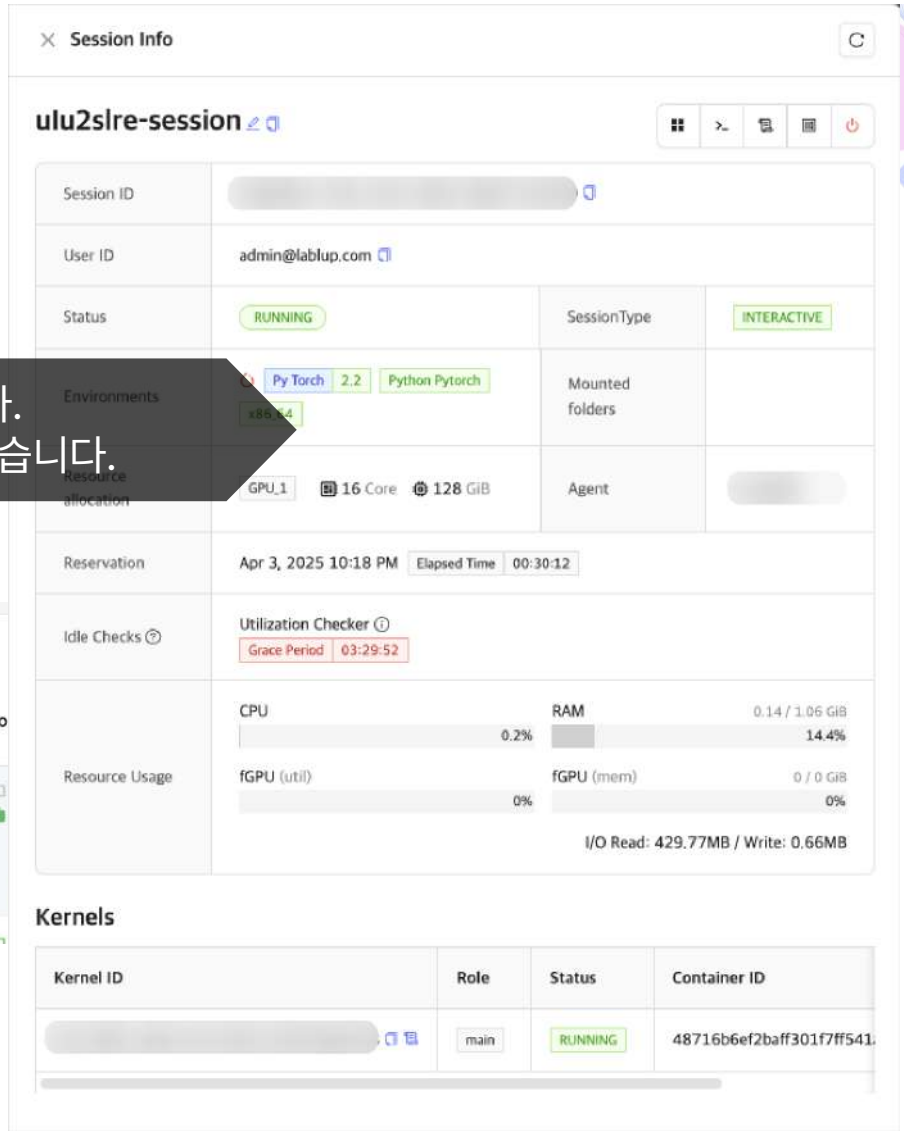

kt cloud CLOUD

lablup

노트북 실행 & 저장소 가져오기

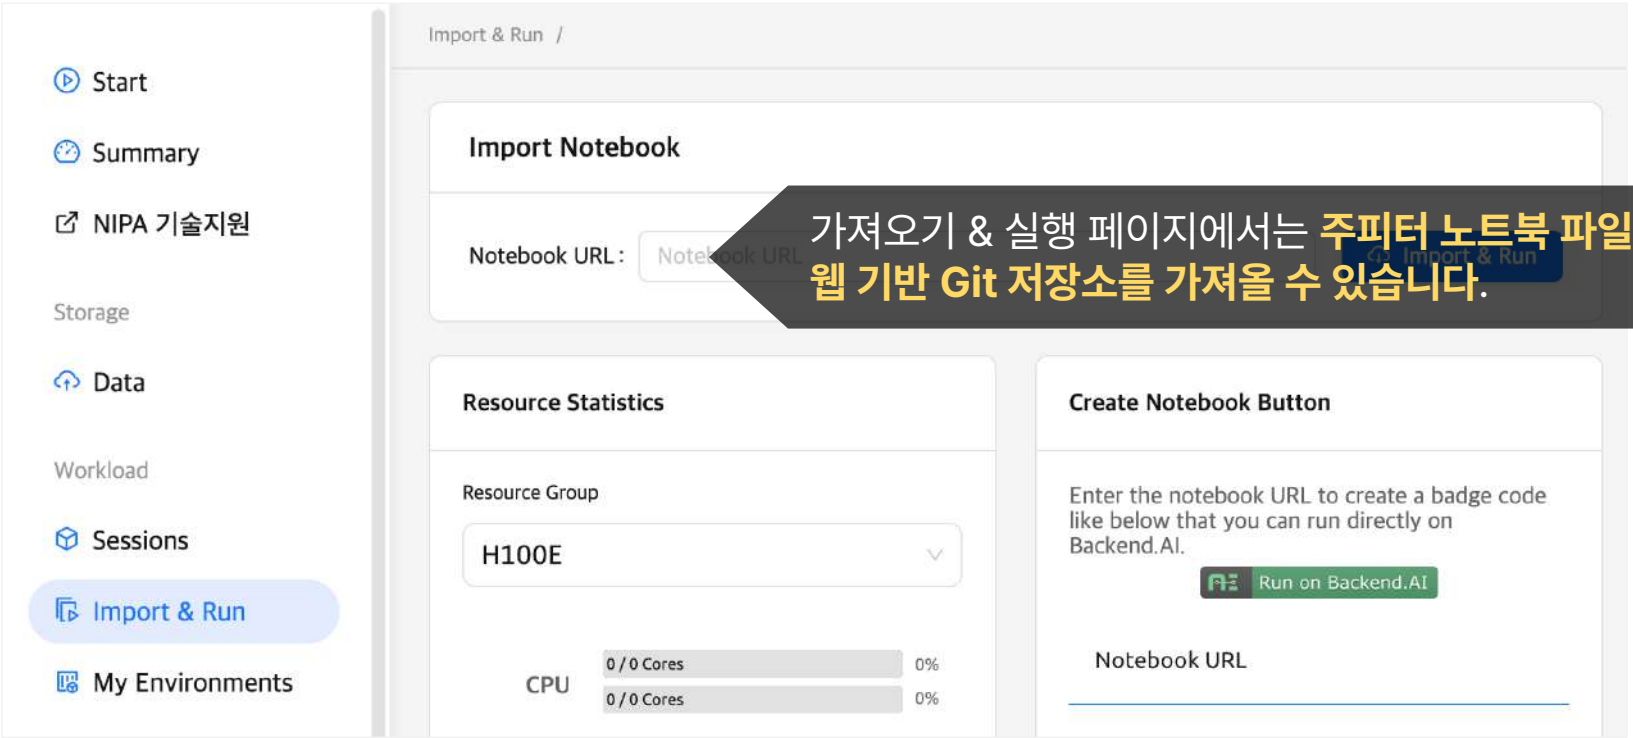

가져오기 & 실행 페이지에서는 **주피터 노트북 파일과 GitHub, GitLab 과 같은 웹 기반 Git 저장소를 가져올 수 있습니다**.

NOTE

가져오기 & 실행 페이지에 대해 자세히 알고 싶다면 다음 링크를 참고하세요:
https://webui.docs.backend.ai/ko/latest/import_run/import_run.html.

kt cloud CLOUD

lablup

컨테이너 커밋 : 사용자 활용 이미지 생성

Q. 이미지 커밋 시 저장되는 데이터는 어떤 것들이 있나요?

A. 패키지가 설치되거나 데이터가 저장되는 경로에 따라 다릅니다. 저장되는 데이터와 그렇지 않은 데이터에 대해서는 아래 내용을 참고하시기 바랍니다.

저장되는 데이터	저장되지 않는 데이터
• `sudo` 권한으로 `pip/apt install` 을 통해 설치하는 패키지 • `/home/work` 경로가 아닌 특정 디렉토리 경로	• `/home/work` (로컬 디스크에 mount 되는 scratch 디렉토리 경로), 일반 폴더, 자동 마운트 폴더 등 • `pip install` 을 통해 설치한 사용자 레벨 레포지토리(단, `.local` 을 자동 마운트 폴더로 지정하면 재사용 가능) • 별도 mount 한 NAS 폴더 (다음 세션 생성 시, 다시 mount 하여 사용할 수 있지만, 커밋한 이미지 자체에는 데이터가 저장되지 않음)

컨테이너 커밋 : 사용자 활용 이미지 생성

TIP
PyPI 패키지를 새 이미지에 포함하려면
`sudo pip install` 을 해야 합니다.

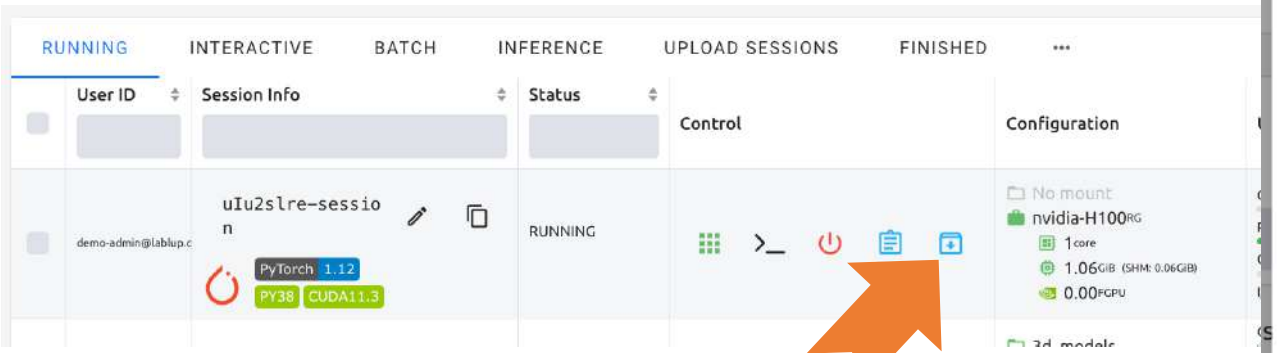

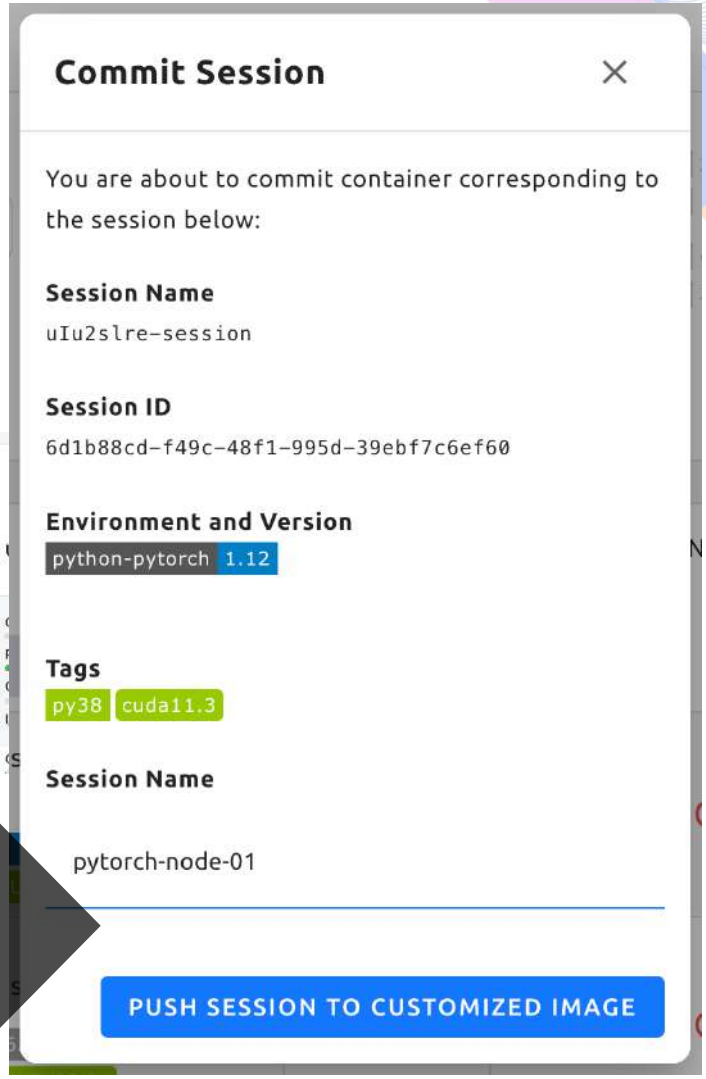

커밋 아이콘을 클릭하면 모달이 띄워집니다. 아래 체크박스를 클릭하고 구별가능한 이름을 적은 후 아래 확인 버튼을 클릭합니다. 잠시 기다리면 **현재 main 컨테이너를 커밋하고 실제 세션으로 재활용할 수 있는 이미지가 생성**되어, 연산 세션 생성 다이얼로그의 환경 이미지로 노출됩니다.

컨테이너 커밋 : 사용자 활용 이미지 생성

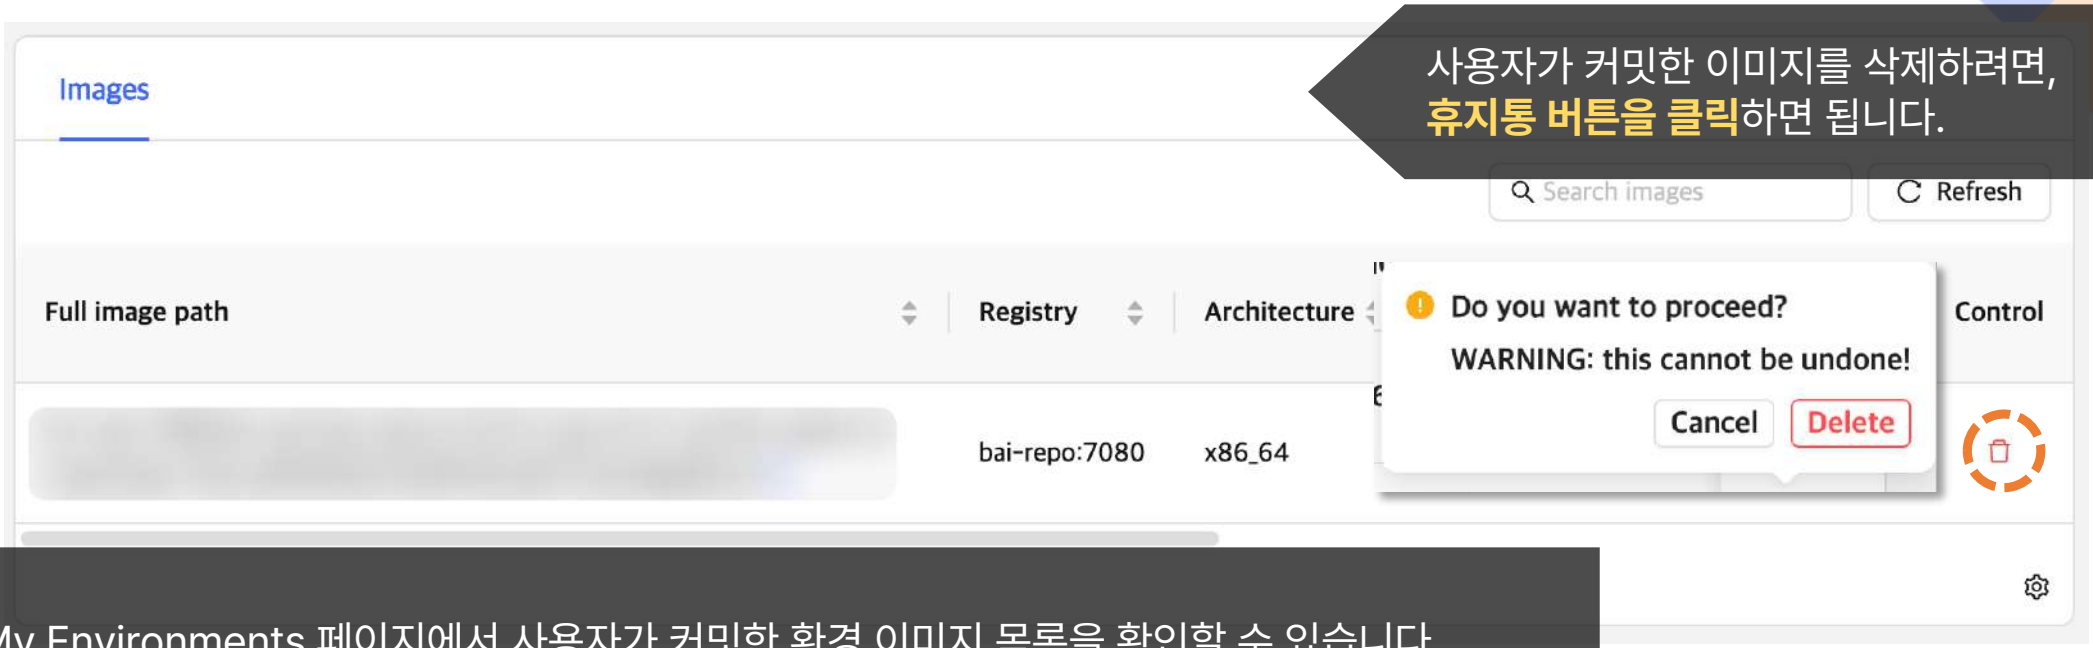

사용자가 커밋한 이미지를 삭제하려면,
휴지통 버튼을 클릭하면 됩니다.

My Environments 페이지에서 사용자가 커밋한 환경 이미지 목록을 확인할 수 있습니다.
이 이미지는 다른 사용자에게는 보이지 않고, 현재 로그인된 사용자만 조회할 수 있습니다.
최대 커밋 이미지 생성 개수에는 제한이 있으므로, **필요없는 이미지는 삭제하는 것이 좋습니다**.

컨테이너 커밋 : 사용자 활용 이미지 생성

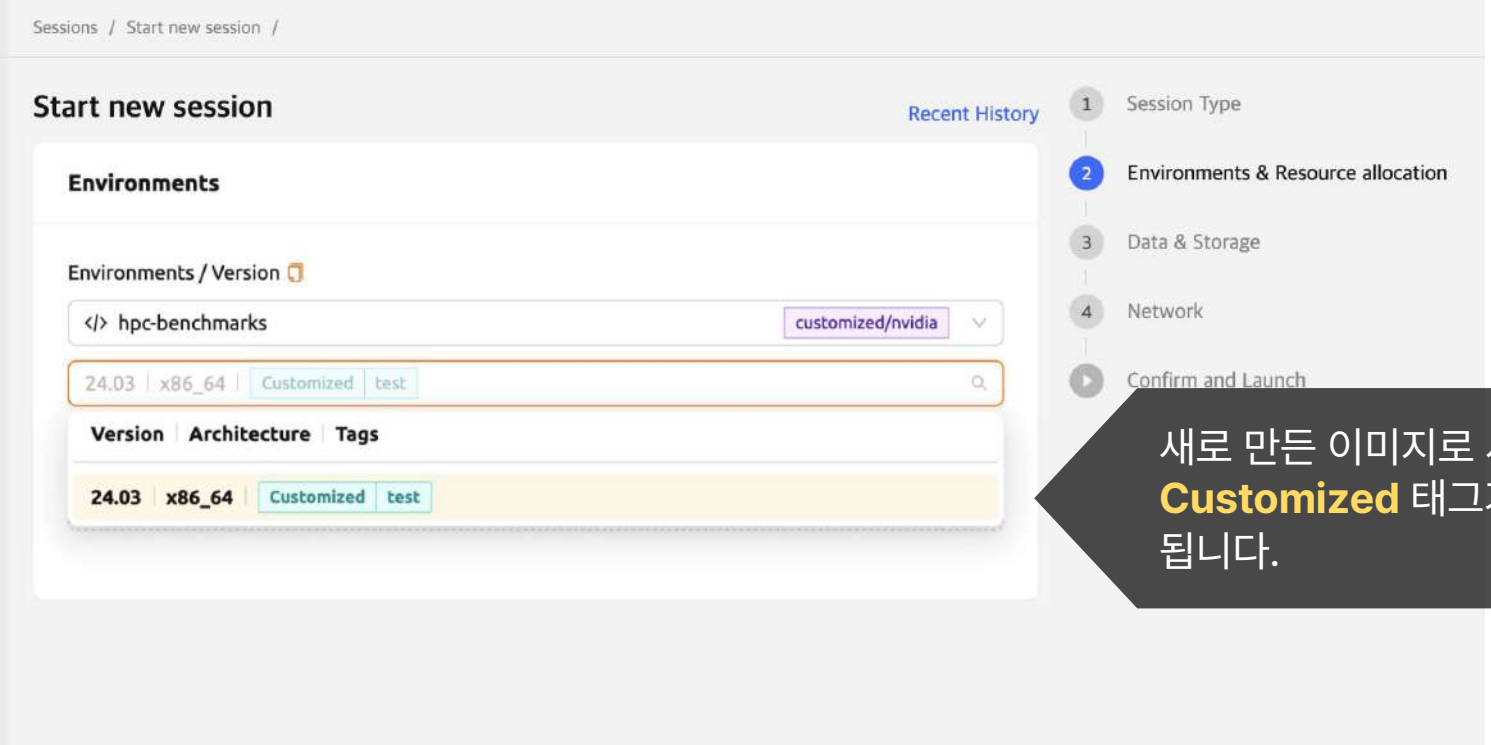

새로 만든 이미지로 세션을 생성하려면,
Customized 태그가 붙어있는 버전을 선택하면 됩니다.

kt cloud CLOUD

lablup

For more information,

Lablup Inc.	https://www.lablup.com
Backend.AI	https://www.backend.ai
Backend.AI GitHub	https://github.com/lablup/backend.ai
Backend.AI Cloud (beta)	https://cloud.backend.ai
API/Core	https://docs.backend.ai/en/latest/
GUI Web-UI	https://webui.docs.backend.ai/en/latest/
CLI Client / SDK	https://docs.client-py.backend.ai/en/latest/

kt cloud
CLOUD